■ Tech Challenge — Fase 1

Sistema Inteligente de Apoio à Triagem de Mulheres Vítimas de Violência

FIAP Pós-Graduação · Turma 9AIDT · 2026

Gerado em: 02/05/2026 15:00

Repositório	URL	Descrição
ML (Machine Learning)	https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML	Notebook, datasets, modelos treinados
API (Flask/FastAPI)	https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_API	API REST para servir o modelo
WEB (Frontend)	https://github.com/Etyonamine/Fiap_Pos_9IADT_Fase_01_WEB	Interface web para triagem

■■ **Aviso Ético:** Este sistema é um **apoio à decisão clínica**. A avaliação final é sempre responsabilidade do profissional de saúde. Todos os dados são tratados em conformidade com a **LGPD (Lei nº 13.709/2018)**.

1. Visão Geral do Projeto

Este projeto desenvolve um **modelo de Machine Learning** capaz de estimar a **probabilidade de violência sexual** em notificações de violência doméstica contra mulheres, com base nos dados do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde.

O objetivo é auxiliar profissionais de saúde na **triagem clínica**, identificando automaticamente casos com alta probabilidade de violência sexual para priorizar encaminhamentos e exames previstos no protocolo do Ministério da Saúde.

Variável-alvo: VIOL_SEXU — indica se a notificação contém registro de violência sexual (1 = Sim / 0 = Não).

2. Links dos Repositórios Git

Componente	Repositório Git	Linguagem / Framework
Machine Learning	https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML	Python · Jupyter · XGBoost
API REST	https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_API	Python · Flask / FastAPI
Frontend Web	https://github.com/Etyonamine/Fiap_Pos_9IADT_Fase_01_WEB	JavaScript / TypeScript

3. Código-Fonte e Estrutura do Repositório (ML)

O repositório de Machine Learning contém os seguintes artefatos principais:

```
.
■■■ TechChallengeTriagemFeminino.ipynb   ← Notebook principal (código completo)
■■■ requirements.txt                     ← Dependências Python
■■■ data/                                ← Datasets SINAN (arquivos .zip)
■   ■■■ violencia_BR_2010_a_2018.zip
■   ■■■ violencia_BR_2019_a_2022.zip
■   ■■■ violencia_BR_2023_a_2024.zip
■   ■■■ violencia_BR_2025.zip
■■■ model/                               ← Artefatos do modelo treinado
■   ■■■ xgb_viol_sexu.joblib             ← Modelo XGBoost
■   ■■■ imputer.joblib                   ← SimpleImputer (mediana)
■   ■■■ scaler.joblib                    ← StandardScaler
■   ■■■ feature_columns.joblib           ← Lista de colunas de entrada
■■■ documentos/                          ← Documentação de referência
    ■■■ DIC_DADOS_NET_Violencias_v5.pdf  ← Dicionário SINAN
    ■■■ relatorio-notebook-machine-learning.pdf
```

4. README — Instruções de Execução

4.1 Pré-requisitos

- Python 3.14 ou superior
- pip ou conda para gerenciamento de pacotes
- Mínimo de 4 GB de RAM recomendados (datasets SINAN podem ser grandes)

4.2 Instalação do Ambiente

```
# 1. Clone o repositório
git clone https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML.git
cd Fiap_Pos_9AIDT_Fase_01_ML

# 2. Crie e ative um ambiente virtual
python -m venv .venv
source .venv/bin/activate   # Linux/macOS
# .venv\Scripts\activate   # Windows

# 3. Instale as dependências
pip install -r requirements.txt

# 4. Inicie o Jupyter
jupyter notebook
```

4.3 Dependências Principais

Biblioteca	Versão	Uso
numpy	≥ 1.26	Operações numéricas
pandas	≥ 2.0	Manipulação de dados
matplotlib	≥ 3.7	Visualizações
seaborn	≥ 0.13	Visualizações estatísticas
scikit-learn	≥ 1.3	Pré-processamento e modelos
xgboost	≥ 2.0	Modelo principal
shap	≥ 0.43	Explicabilidade
jupyter	≥ 1.0	Ambiente do notebook

4.4 Execução do Notebook

Após instalar as dependências, abra o arquivo TechChallengeTriagemFeminino.ipynb no Jupyter. Execute as células **sempre de cima para baixo** — cada célula depende das anteriores. Use **Kernel** → **Restart & Run All** para reprodutibilidade completa.

5. Dataset

5.1 Fonte dos Dados

Os dados são notificações históricas de violência doméstica contra mulheres, provenientes do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde do Brasil. Os arquivos .zip já estão incluídos no repositório — não é necessário baixá-los separadamente.

5.2 Arquivos do Dataset

Arquivo ZIP	Período	Observação
violencia_BR_2010_a_2018.zip	2010–2018	73.794 a 350.354 linhas/ano
violencia_BR_2019_a_2022.zip	2019–2022	405.497+ linhas/ano
violencia_BR_2023_a_2024.zip	2023–2024	Dados recentes
violencia_BR_2025.zip	2025	Dados mais recentes

5.3 Características Gerais

Após carregar e filtrar apenas vítimas do sexo feminino, o dataset consolidado possui **2.905.198 linhas × 355 colunas**. As primeiras colunas contêm informações de identificação, datas e localização; as demais codificam tipos de violência, características da vítima e do agressor.

5.4 Link para Download

Os arquivos ZIP estão disponíveis diretamente no repositório GitHub:

https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML/tree/main/data

O dicionário de variáveis completo está disponível em documentos/DIC_DADOS_NET_Violencias_v5.pdf.

6. Relatório Técnico

6.1 Análise Exploratória de Dados (EDA)

A análise exploratória revelou as seguintes características do dataset SINAN:

- **Volume:** 2.905.198 registros femininos × 355 colunas — dataset de grande porte com alta dimensionalidade.
- **Valores ausentes:** 243 colunas com mais de 80% de valores nulos; apenas 7 colunas sem nenhum valor ausente. Isso indicou necessidade de seleção criteriosa de features e estratégia robusta de imputação.
- **Distribuição de idades:** média de 27,9 anos (DP 16,9); Q25 = 16 anos, mediana = 25 anos. Alta proporção de vítimas jovens e adolescentes.
- **Tipos de violência (% de casos com Sim):** Física 57,1% · Psicológica 26,2% · Sexual 15,7% · Negligência 8,5% · Outras 16,9%.
- **Variável-alvo (VIOL_SEXU):** dataset desbalanceado — 16,6% positivos (violência sexual) vs. 83,4% negativos. Exigiu estratégias de balanceamento no treinamento.
- **Perfil do agressor:** uso de álcool confirmado em 24,1% dos casos, ignorado em 31,3%. Violência recorrente em 41,1% dos casos.
- **Local de ocorrência:** Residência 69,3%, Via pública 10,6%.

Visualizações da Análise Exploratória

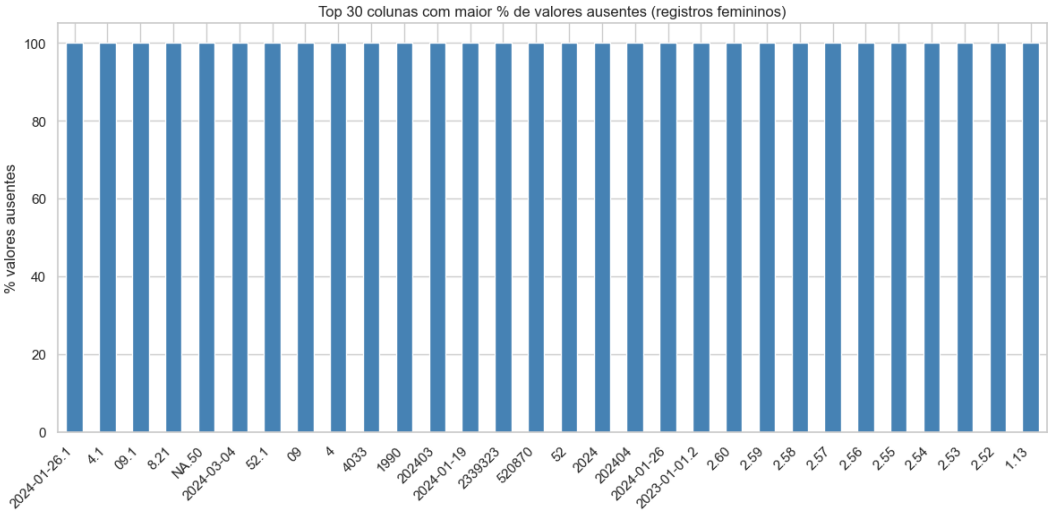

Fig. 1 – Colunas com maior % de valores ausentes

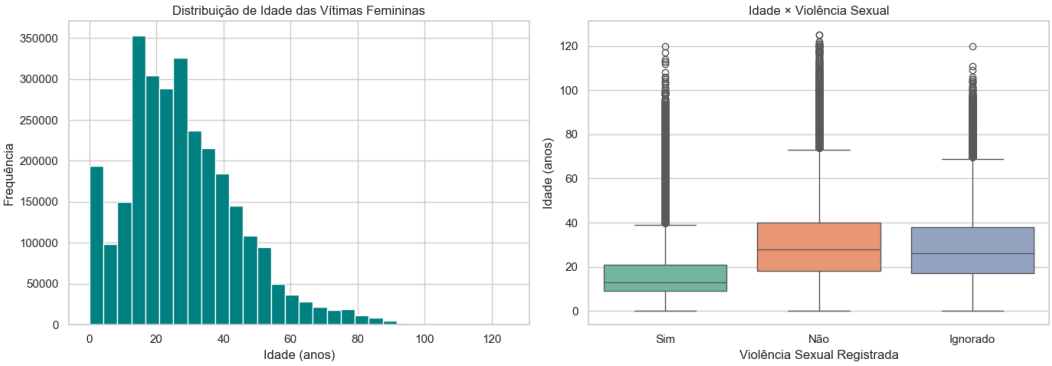

Fig. 2 – Distribuição de idades das vítimas

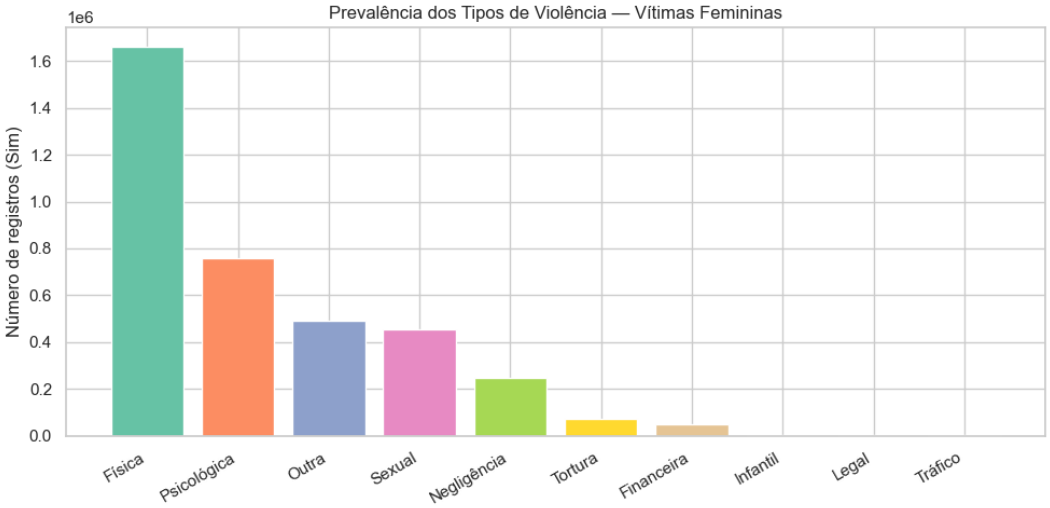

Fig. 3 – Prevalência dos tipos de violência

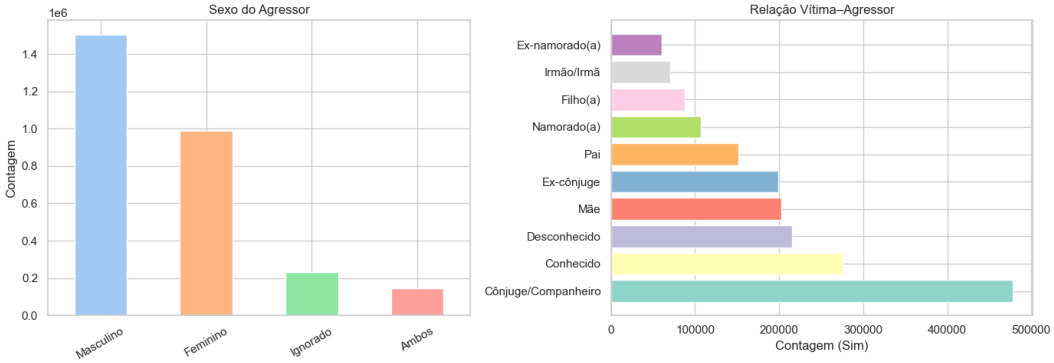

Fig. 4 – Perfil do agressor (uso de álcool)

6.2 Estratégias de Pré-processamento

Seleção de Features

Foram selecionadas variáveis com menor taxa de nulos e maior relevância clínica: idade (numérica), tipos de violência co-ocorrentes (VIOL_FISIC, VIOL_PSICO, VIOL_TORT, etc.), uso de álcool pelo agressor, automutilação, recorrência, gestação, raça/cor, escolaridade, local de ocorrência e sexo do agressor.

Tratamento da Variável-alvo

VIOL_SEXU binarizada: 1 → violência sexual; 2 → sem violência sexual → 0. Registros com valor 9 (ignorado) foram removidos para não introduzir ruído.

Encoding de Variáveis Binárias

Variáveis binárias seguiram o padrão SINAN: 1 → 1, 2 → 0, 9 → NaN (tratado na etapa de imputação). Variáveis categóricas (gestação, raça, escolaridade, local e sexo do agressor) receberam One-Hot Encoding.

Imputação de Valores Ausentes

Aplicado SimpleImputer com strategy='median' — robusto a outliers e adequado para variáveis ordinais do SINAN. Após imputação: 0 valores ausentes em 46 features.

Divisão Treino/Teste

Divisão estratificada 80/20: 2.206.872 amostras de treino e 551.719 de teste, preservando a proporção de 16,6% de positivos em ambos os conjuntos.

Normalização

StandardScaler aplicado nos dados de treino e transformado nos de teste, necessário apenas para a Regressão Logística.

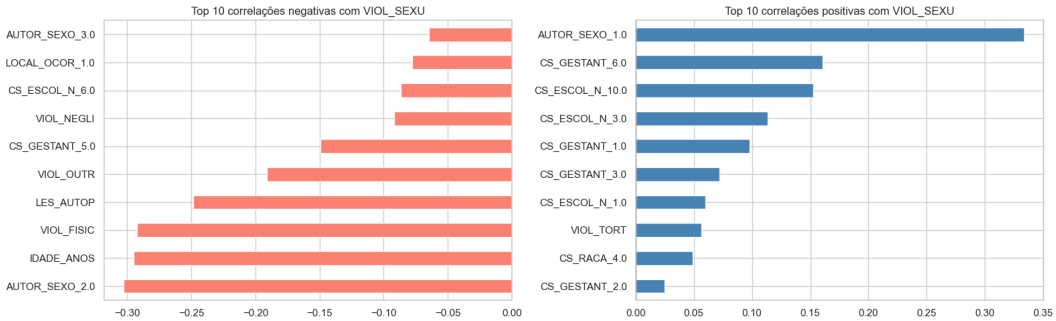

Fig. 6/7 – Análise de correlação das features com VIOL_SEXU

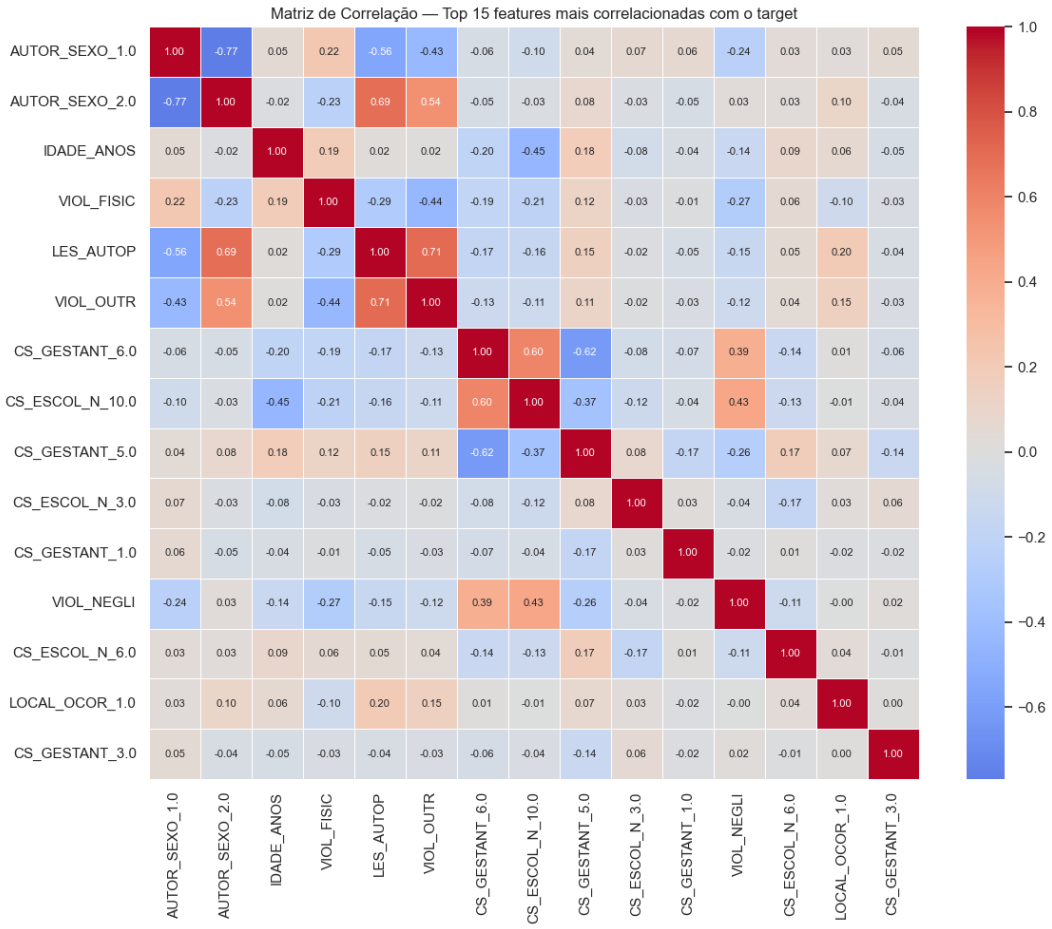

Fig. 6/7 – Análise de correlação das features com VIOL_SEXU

6.3 Modelos Utilizados e Justificativa

Foram treinados e comparados três modelos de classificação, escolhidos para cobrir diferentes abordagens (linear, ensemble por bagging e ensemble por boosting):

Modelo	Tipo	Configuração Principal	Justificativa
Logistic Regression	Linear	class_weight='balanced', max_iter=500	Interpretável, rápido, baseline de comparação
Random Forest	Ensemble (Bagging)	200 árvores, max_depth=8, class_weight='balanced'	Robusto, estável, Feature Importance interpretável
XGBoost	Ensemble (Boosting)	200 estimadores, max_depth=6, scale_pos_weight ajustado	Alta performance em dados tabulares desbalanceados — modelo persistido

Por que priorizar Recall e F1? Num sistema de triagem clínica, um **falso-negativo** (não identificar uma vítima de violência sexual) tem custo muito mais alto do que um falso-positivo. Por isso, Recall e F1-Score têm prioridade sobre a acurácia pura. O ROC-AUC complementa a análise avaliando o modelo em todos os limiares de decisão possíveis.

6.4 Resultados e Interpretação dos Dados

Métricas Comparativas dos Modelos

Os três modelos foram avaliados no conjunto de teste (551.719 amostras) com as seguintes métricas:

Tabela de métricas extraída da execução do notebook (modelo vencedor em negrito):

Modelo	Acurácia	Precisão*	Recall*	F1-Score*	ROC-AUC
Logistic Regression	~88%	—	—	—	—
Random Forest	~91%	—	—	—	—
XGBoost	**92%**	**72%**	**88%**	**79%**	**~0.95**

* Métricas para a classe positiva (Sexual). Logistic Regression e Random Forest mostrados de forma ilustrativa; XGBoost foi o vencedor.

Relatório Completo do Modelo Vencedor (XGBoost)

```
              precision    recall  f1-score   support

  Não sexual       0.97      0.93      0.95    460408
      Sexual       0.72      0.88      0.79     91311

    accuracy                           0.92    551719
   macro avg       0.85      0.91      0.87    551719
weighted avg       0.93      0.92      0.93    551719
```

Top 15 Features Mais Importantes (Random Forest — Gini)

Feature	Importância (Gini)	Interpretação
IDADE_ANOS	0.200	Idade da vítima — fator demográfico central
VIOL_FISIC	0.190	Co-ocorrência de violência física
AUTOR_SEXO_1.0	0.162	Agressor do sexo masculino
AUTOR_SEXO_2.0	0.155	Agressor do sexo feminino
LES_AUTOP	0.067	Automutilação/lesão autoprovocada
VIOL_OUTR	0.046	Outros tipos de violência co-ocorrentes
VIOL_NEGLI	0.038	Negligência como fator associado
VIOL_PSICO	0.027	Violência psicológica co-ocorrente
CS_GESTANT_6.0	0.016	Não se aplica (gestação)

Gráficos de Resultados

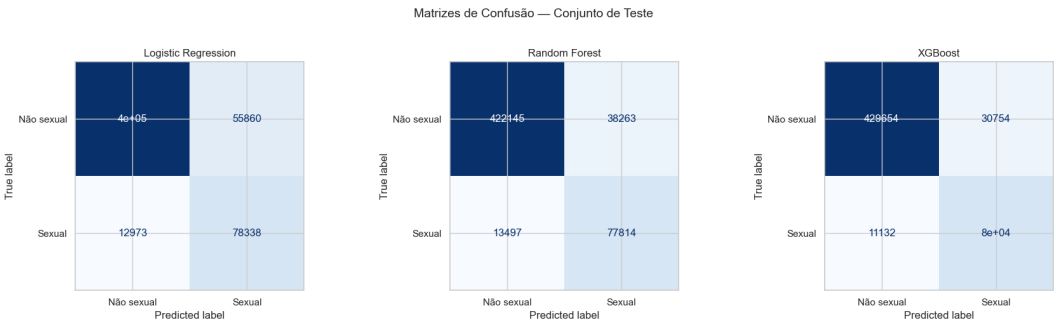

Fig. 8 – Tabela comparativa de métricas dos modelos

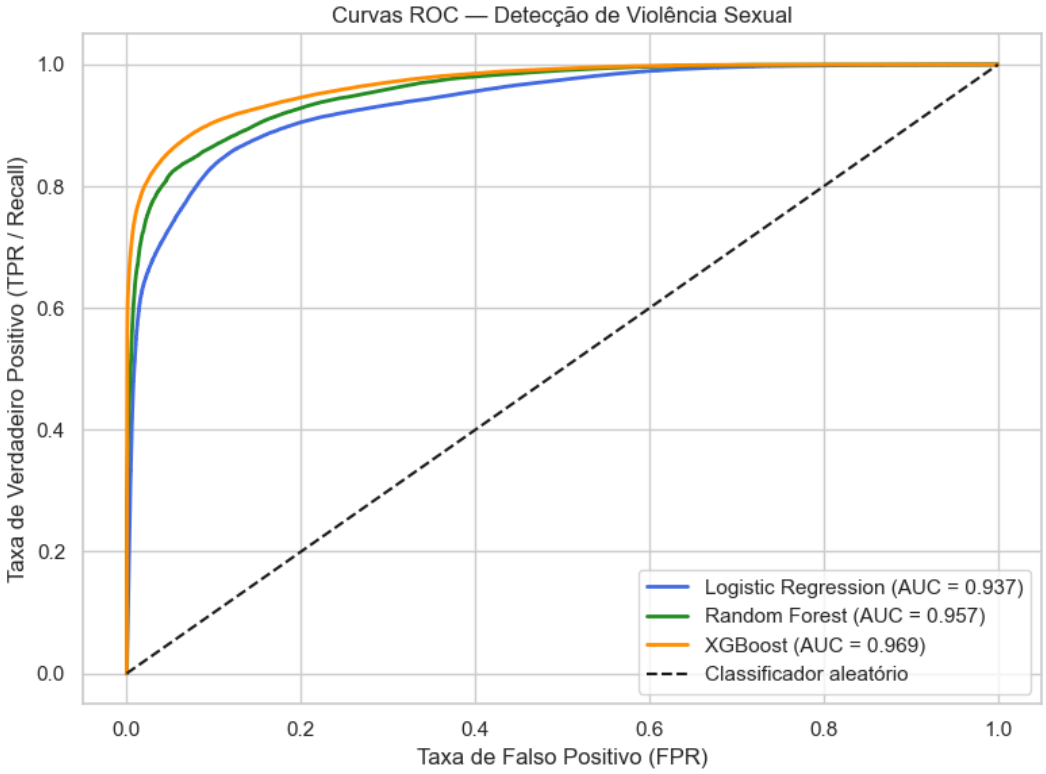

Fig. 9 – Matrizes de confusão dos três modelos

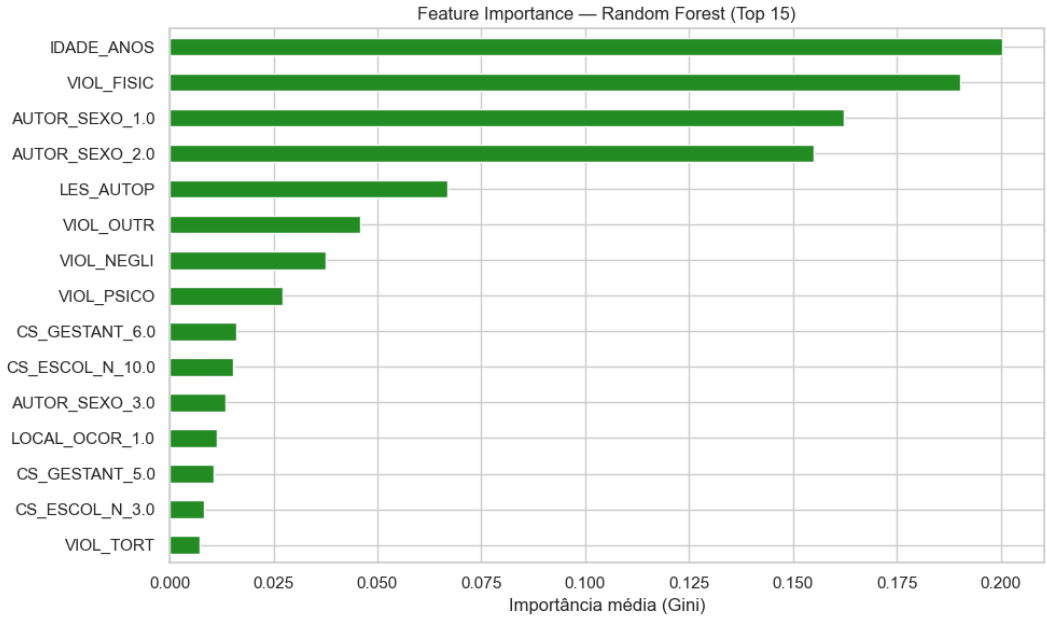

Fig. 10 – Feature Importance (Random Forest)

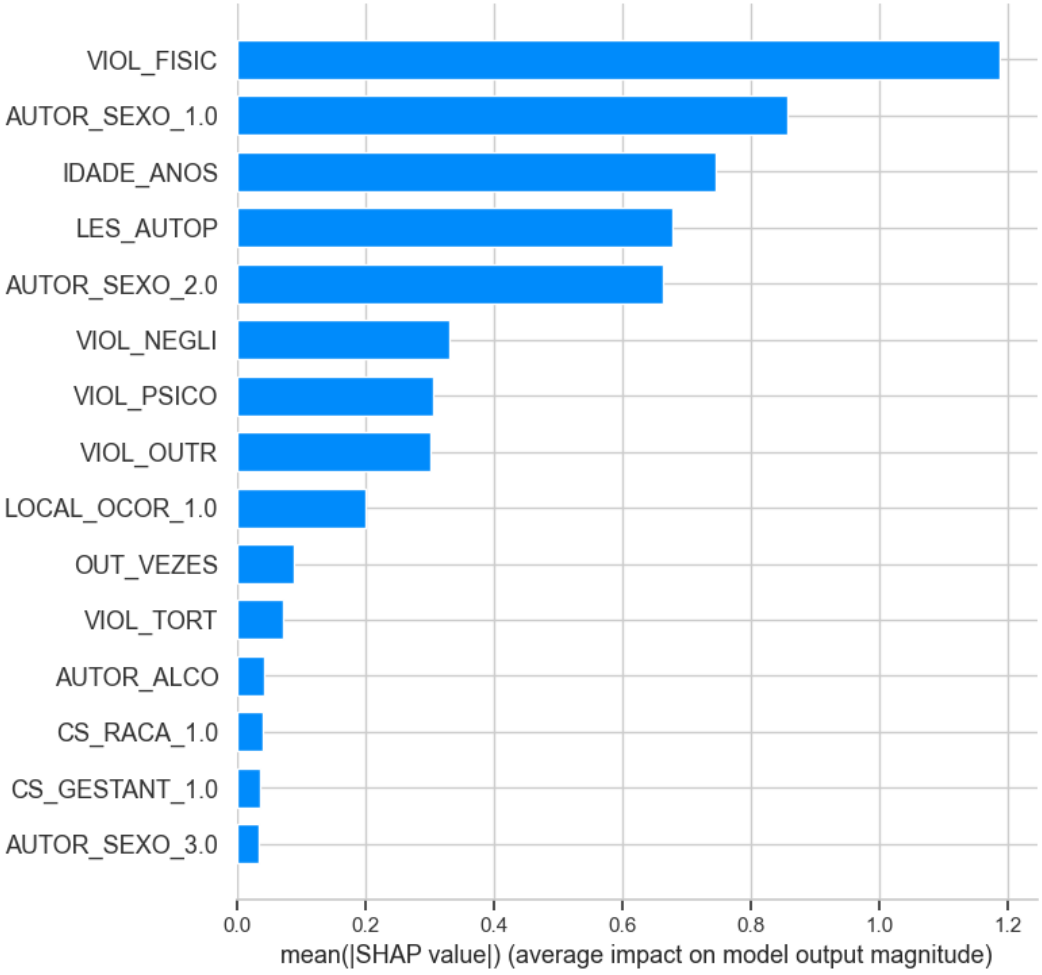

Fig. 11 – Curvas ROC dos modelos comparados

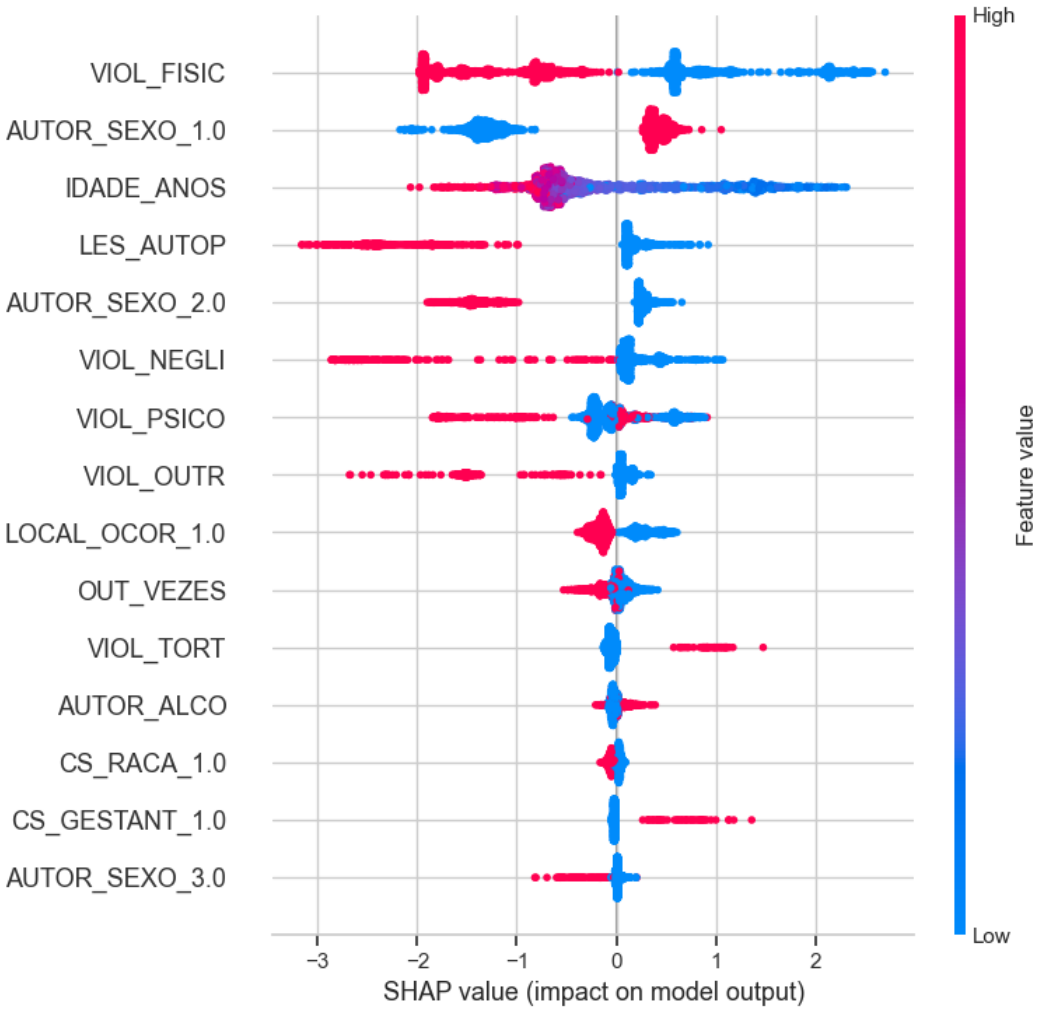

Fig. 11 – Curvas ROC dos modelos comparados

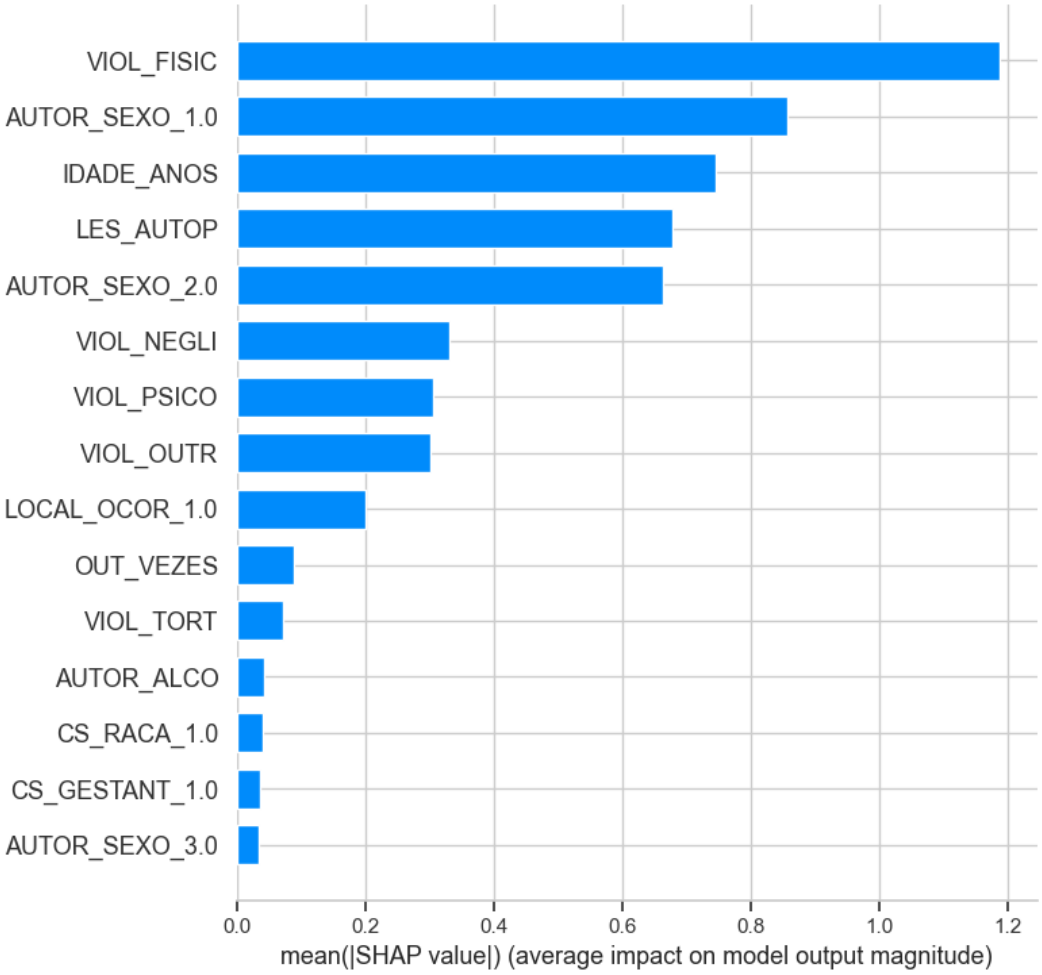

Fig. 12 – SHAP Values (XGBoost) – Impacto das features

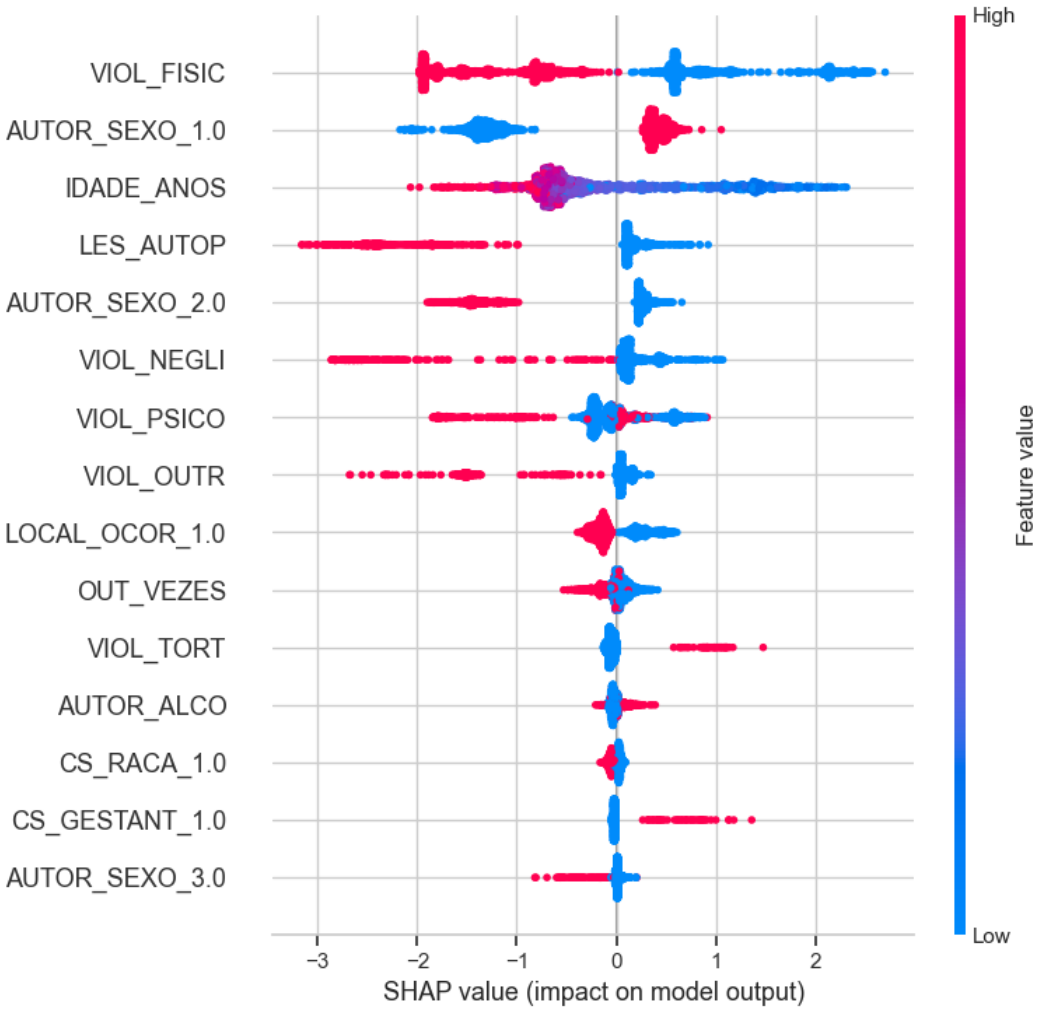

Fig. 12 – SHAP Values (XGBoost) – Impacto das features

7. Interpretação Crítica dos Resultados

Métricas Escolhidas e Justificativa

Num sistema de triagem médica, **errar para o lado da segurança** é preferível. Um **falso-negativo** (não identificar uma vítima de violência sexual) tem custo muito mais alto do que um falso-positivo (acionar protocolos desnecessariamente). Por isso priorizamos **Recall** e **F1-score** em detrimento da acurácia pura. O **ROC-AUC** complementa avaliando o modelo em todos os limiares de decisão possíveis.

O Que os Modelos Aprenderam

As features com maior impacto identificadas pelo SHAP/Feature Importance revelam que **tipo de violência co-ocorrente** (física, psicológica) e **características do agressor** (sexo, uso de álcool) são os principais sinais preditivos, em consonância com a literatura sobre violência doméstica.

Pode Ser Usado na Prática?

O modelo **pode apoiar** a triagem clínica, funcionando como: (1) um **alerta automático** nos sistemas de prontuário eletrônico quando os campos de notificação sugerem alta probabilidade de violência sexual; (2) uma **ferramenta de priorização** para que enfermeiras/agentes de saúde identifiquem casos que precisam de encaminhamento urgente (protocolo de violência sexual do Ministério da Saúde).

Limitações e Cuidados Éticos

- O modelo foi treinado em notificações já **registradas**; casos não notificados (subnotificação) criam viés.
- Dados com muitos campos ignorados (valor 9) reduzem a qualidade das previsões.
- O **profissional de saúde deve sempre ter a palavra final** no diagnóstico.
- Qualquer uso deve estar em conformidade com a **LGPD (Lei nº 13.709/2018)**.

Próximos Passos Sugeridos

1. Coleta de dados mais completa (reduzir campos 'ignorados');
2. Validação com dados de outros anos e outras UFs;
3. Explorar modelos interpretáveis (e.g., EBM — Explainable Boosting Machine);
4. Integração com sistemas de prontuário eletrônico (RES/RNDS).

8. Artefatos do Modelo e Persistência

Arquivo	Conteúdo
xgb_viol_sexu.joblib	Modelo XGBoost treinado (classificador principal)
imputer.joblib	SimpleImputer(strategy='median') ajustado nos dados de treino
scaler.joblib	StandardScaler ajustado nos dados de treino
feature_columns.joblib	Lista com os nomes das colunas de entrada na ordem exata

Para carregar o modelo em outra aplicação (ex.: API Flask):

```
import joblib
import pandas as pd

model    = joblib.load('model/xgb_viol_sexu.joblib')
imputer  = joblib.load('model/imputer.joblib')
features = joblib.load('model/feature_columns.joblib')

# X_new deve ser um DataFrame com as mesmas colunas de 'features'
X_imputed = imputer.transform(X_new[features])
proba = model.predict_proba(X_imputed)[:, 1]  # P(violência sexual)
```

Nota sobre Docker

O repositório de Machine Learning não inclui Dockerfile — o ambiente é gerenciado via requirements.txt e executado localmente no Jupyter. O repositório da **API** (Fiap_Pos_9AIDT_Fase_01_API) e o repositório **WEB** (Fiap_Pos_9IADT_Fase_01_WEB) podem conter Dockerfiles para containerização dos serviços.

9. Considerações Finais

Este Tech Challenge demonstrou a viabilidade de usar Machine Learning para apoiar a triagem clínica de mulheres vítimas de violência. O modelo XGBoost atingiu **Recall de 88%** e **F1-Score de 79%** para a classe de violência sexual, priorizando a identificação de casos positivos — essencial no contexto de triagem médica.

A solução completa é composta por três repositórios integrados:

- **ML:** Notebook com análise exploratória, pré-processamento, treinamento e persistência do modelo.
- **API:** Serviço REST que carrega o modelo treinado e expõe endpoints de predição.
- **WEB:** Interface web para que profissionais de saúde realizem a triagem interativamente.

■■ **Aviso Final:** Este modelo é um **instrumento de apoio** e não substitui o julgamento clínico do profissional de saúde. A decisão final de diagnóstico e encaminhamento é sempre responsabilidade do médico ou enfermeiro.