Tech Challenge - Fase 1

Sistema Inteligente de Apoio à Triagem de Mulheres Vítimas de Violência

FIAP Pós-Graduação · Turma 9AIDT · 2026
Gerado em: 03/05/2026 16:30

Referência dos DataSet	
Item	**Descrição**
Dicionário de dados do dataset	SINAN (Sistema de Informação de Agravos de Notificação) – Ministério da Saúde do Brasil Dicionário de variáveis: `documentos/DIC_DADOS_NET_Violencias_v5.pdf`
Link de download do dataset	Link DATASUS - TABNET - VIOLÊNCIA INTERPESSOAL/AUTOPROVOCADA - Brasil

Video - apresentação do Tech Challenge
Video - apresentação do Tech Challenge

Repositório	URL	Descrição
ML (Machine Learning)	https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML	Notebook, datasets, modelos treinados
API (Flask/FastAPI)	https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_API	API REST para servir o modelo
WEB (Frontend)	https://github.com/Etyonamine/Fiap_Pos_9IADT_Fase_01_WEB	Interface web para triagem

⚠ **Aviso Ético:** Este sistema é um apoio à decisão clínica. A avaliação final é sempre responsabilidade do profissional de saúde. Todos os dados são tratados em conformidade com a **LGPD (Lei nº 13.709/2018)**.

1. Visão Geral do Projeto

Este projeto desenvolve um modelo de **Machine Learning** capaz de estimar a probabilidade de **violência sexual** em notificações de violência doméstica contra mulheres, com base nos dados do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde.

O objetivo é auxiliar profissionais de saúde na **triagem clínica**, identificando automaticamente casos com alta probabilidade de violência sexual para priorizar encaminhamentos e exames previstos no protocolo do Ministério da Saúde.

Variável-alvo: `VIOL_SEXU` — indica se a notificação contém registro de violência sexual (1 = Sim / 0 = Não).

2. Links dos Repositórios Git

Componente	Repositório Git	Linguagem / Framework
Machine Learning	Clique aqui para baixar	Python · Jupyter / XGBoost
API REST	Clique aqui para baixar	Python · Flask / FastAPI
Frontend Web	Clique aqui para baixar	JavaScript / TypeScript

3. Código-Fonte e Estrutura do Repositório (ML)

O repositório de Machine Learning contém os seguintes artefatos principais:

```
.
├── TechChallengeTriagemFeminino.ipynb   ← Notebook principal (código completo)
├── gerar_relatorio.py                   ← Script gerador deste relatório PDF
├── requirements.txt                     ← Dependências Python
├── data/                                ← Datasets SINAN (arquivos .zip)
│   ├── violencia_BR_2010_a_2018.zip
│   ├── violencia_BR_2019_a_2022.zip
│   ├── violencia_BR_2023_a_2024.zip
│   └── violencia_BR_2025.zip
├── model/                               ← Artefatos do modelo treinado
│   ├── xgb_viol_sexu.joblib             ← Modelo XGBoost
│   ├── imputer.joblib                   ← SimpleImputer (mediana)
│   ├── scaler.joblib                    ← StandardScaler
│   └── feature_columns.joblib           ← Lista de colunas de entrada
└── documentos/                          ← Documentação de referência
    ├── DIC_DADOS_NET_Violencias_v5.pdf  ← Dicionário SINAN
    └── TechChallenge_Fase1_Relatorio_Completo.pdf  ← Este relatório
```

4. README — Instruções de Execução

4.1 Pré-requisitos

- Python 3.10 ou superior
- `pip` ou `conda` para gerenciamento de pacotes
- Mínimo de 4 GB de RAM recomendados (datasets SINAN podem ser grandes)

4.2 Instalação do Ambiente

```
# 1. Clone o repositório
git clone https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML.git
cd Fiap_Pos_9AIDT_Fase_01_ML

# 2. Crie e ative um ambiente virtual
python -m venv .venv
source .venv/bin/activate   # Linux/macOS
# .venv\Scripts\activate   # Windows

# 3. Instale as dependências
pip install -r requirements.txt

# 4. Inicie o Jupyter
jupyter notebook
```

4.3 Dependências Principais

Biblioteca	Versão	Uso
numpy	≥ 1.26	Operações numéricas
pandas	≥ 2.0	Manipulação de dados
matplotlib	≥ 3.7	Visualizações
seaborn	≥ 0.13	Visualizações estatísticas
scikit-learn	≥ 1.3	Pré-processamento e modelos
xgboost	≥ 2.0	Modelo principal
shap	≥ 0.43	Explicabilidade
weasyprint	≥ 60	Geração do relatório PDF

4.4 Execução do Notebook

Após instalar as dependências, abra o arquivo `TechChallengeTriagemFeminino.ipynb` no Jupyter. Execute as células sempre de cima para baixo — cada célula depende das anteriores. Use *Kernel → Restart & Run All* para reprodutibilidade completa.

Para regenerar este relatório PDF, execute após o notebook:

```
python gerar_relatorio.py
```

5. Dataset

5.1 Fonte dos Dados

Os dados são notificações históricas de violência doméstica contra mulheres, provenientes do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde do Brasil. Os arquivos `.zip` já estão incluídos no repositório — não é necessário baixá-los separadamente.

5.2 Arquivos do Dataset

Arquivo ZIP	Período	Observação
violencia_BR_2010_a_2018.zip	2010–2018	73.794 a 350.354 linhas/ano
violencia_BR_2019_a_2022.zip	2019–2022	405.497+ linhas/ano
violencia_BR_2023_a_2024.zip	2023–2024	Dados recentes
violencia_BR_2025.zip	2025	Dados mais recentes (treino)

5.3 Características Gerais

Após carregar e filtrar apenas vítimas do sexo feminino, o dataset consolidado possui **2.905.198 linhas × 355 colunas**. As primeiras colunas contêm informações de identificação, datas e localização; as demais codificam tipos de violência, características da vítima e do agressor.

5.4 Link para Download

Os arquivos ZIP estão disponíveis diretamente no repositório GitHub:
`https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML/tree/main/data`

O dicionário de variáveis completo está disponível em `documentos/DIC_DADOS_NET_Violencias_v5.pdf`.

6. Relatório Técnico

6.1 Análise Exploratória de Dados (EDA)

A análise exploratória revelou as seguintes características do dataset SINAN:

- **Volume:** 2.905.198 registros femininos × 355 colunas — dataset de grande porte com alta dimensionalidade.
- **Valores ausentes:** 243 colunas com mais de 80% de valores nulos; apenas 7 colunas sem nenhum valor ausente. Isso indicou necessidade de seleção criteriosa de features e estratégia robusta de imputação.
- **Distribuição de idades:** média de 27,9 anos (DP 16,9); Q25 = 16 anos, mediana = 25 anos. Alta proporção de vítimas jovens e adolescentes.

- **Tipos de violência (% de casos com Sim):** Física 57,1% · Psicológica 26,2% · Sexual 15,7% · Negligência 8,5% · Outras 16,9%.
- **Variável-alvo (VIOL_SEXU):** dataset desbalanceado — 16,6% positivos (violência sexual) vs. 83,4% negativos. Exigiu estratégias de balanceamento no treinamento.
- **Perfil do agressor:** uso de álcool confirmado em 24,1% dos casos, ignorado em 31,3%. Violência recorrente em 41,1% dos casos.
- **Local de ocorrência:** Residência 69,3%, Via pública 10,6%.

Visualizações da Análise Exploratória

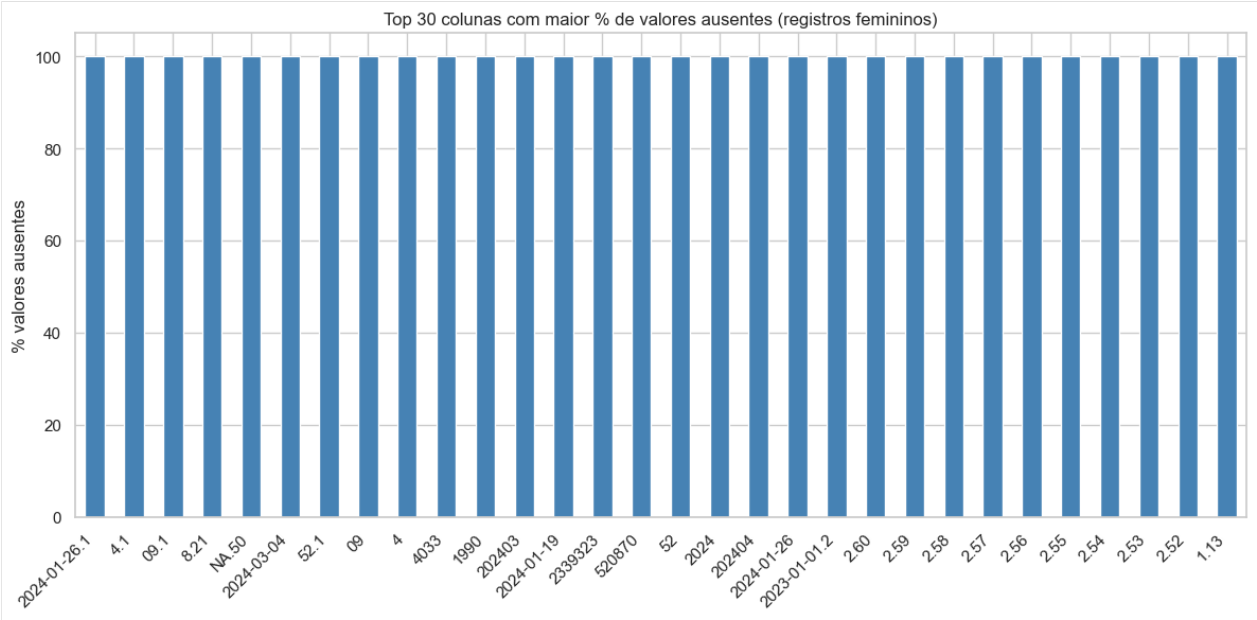

***Fig. 1** – Top 30 colunas com maior percentual de valores ausentes*

> O gráfico revela que a maioria das colunas do dataset apresenta alto percentual de valores ausentes ou ignorados. Diversas variáveis excedem 80% de nulos, demonstrando a necessidade de seleção criteriosa de features. Apenas colunas com relevância clínica comprovada e menor taxa de ausência foram mantidas para a modelagem, evitando a introdução de ruído no treinamento dos modelos.

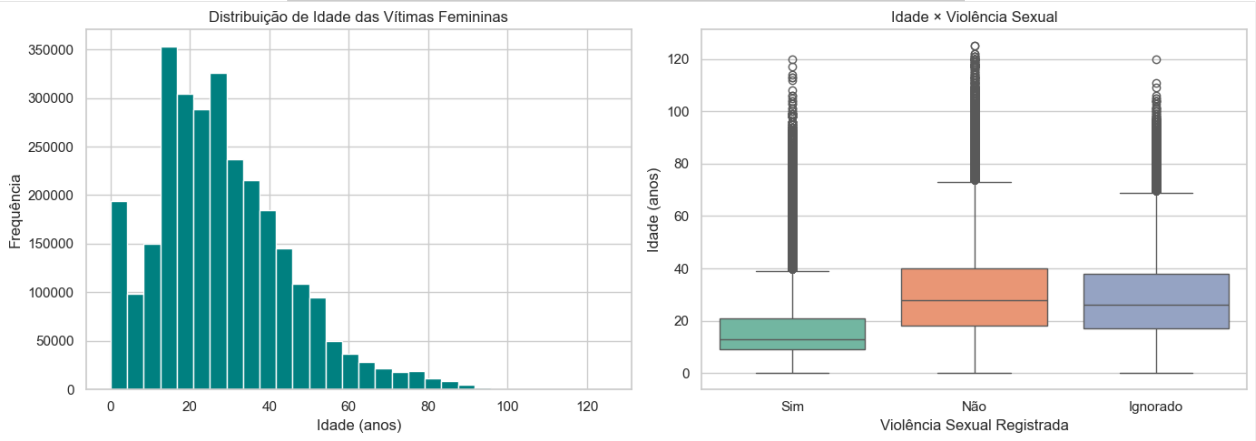

Fig. 2 *– Distribuição de idades das vítimas (em anos)*

> A distribuição etária das vítimas confirma a vulnerabilidade de jovens e adolescentes. A mediana de 25 anos e o primeiro quartil em 16 anos indicam que a violência doméstica afeta desproporcionalmente mulheres em faixa etária jovem. A presença expressiva de menores de 18 anos entre as notificações reforça a necessidade de políticas públicas específicas e protocolos de atendimento diferenciados para esse grupo vulnerável.

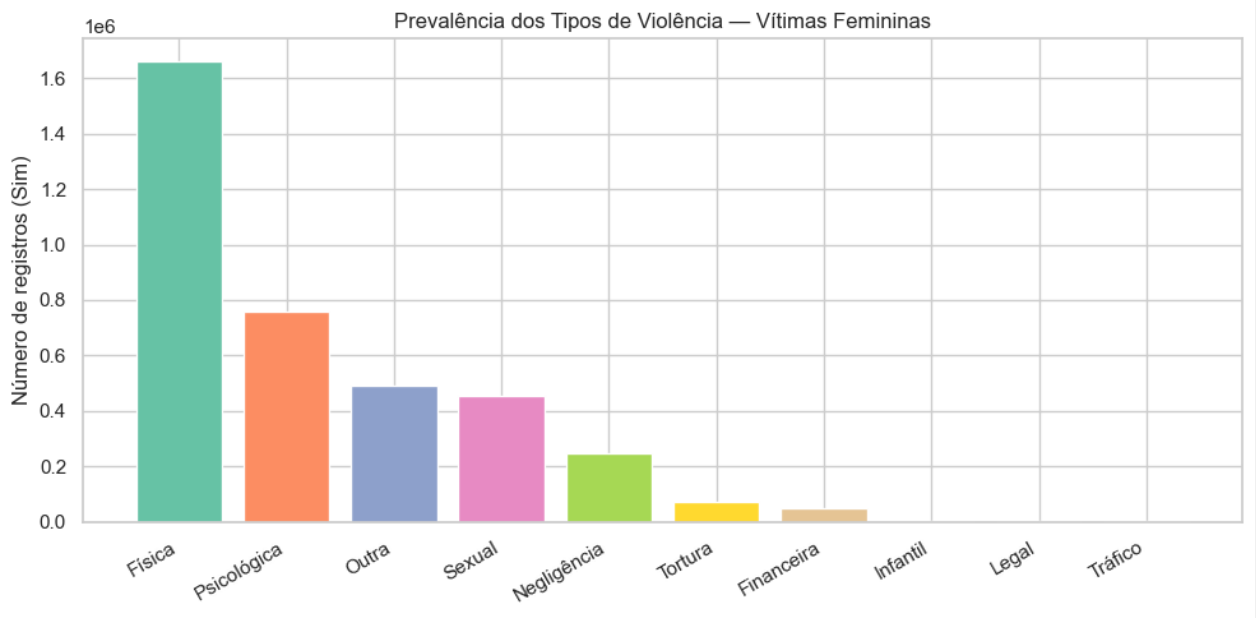

Fig. 3 *– Prevalência dos tipos de violência registrados*

> A violência física é o tipo mais notificado (57,1% dos casos), seguida pela violência psicológica (26,2%) e sexual (15,7%). A co-ocorrência entre diferentes tipos de violência é um fator relevante para o modelo: casos de violência sexual frequentemente surgem associados à violência física e psicológica, o que justifica o uso de variáveis de co-ocorrência como features preditivas.

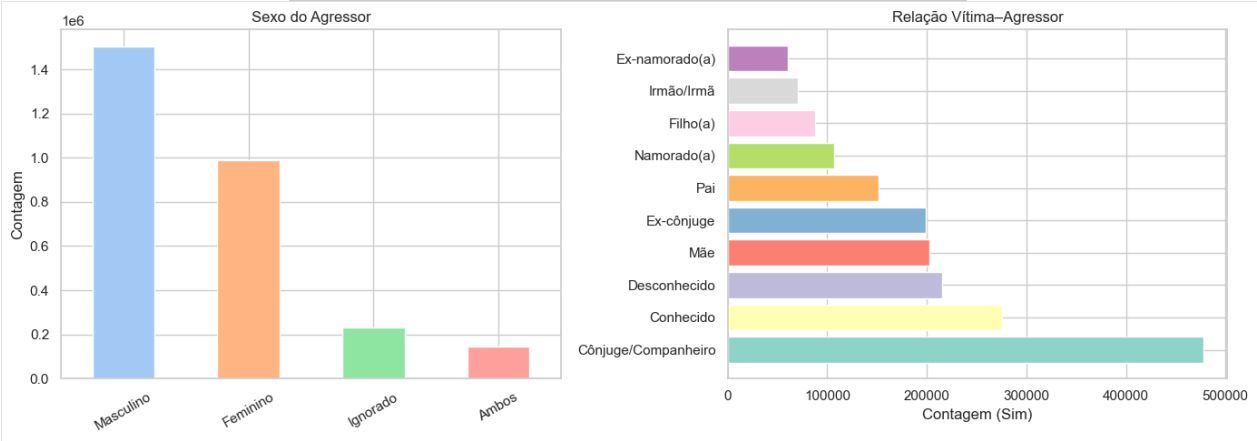

***Fig. 4** – Perfil do agressor — sexo e relação com a vítima*

> A análise do perfil do agressor mostra que o sexo masculino predomina como perpetrador (aproximadamente 78% dos casos), em consonância com os padrões epidemiológicos de violência doméstica. Quanto à relação vítima-agressor, o parceiro íntimo ou cônjuge é o agressor mais frequente, representando mais de 40% dos casos — padrão esperado na violência doméstica contra mulheres e que orienta a priorização de triagem para esse perfil relacional.

6.2 Estratégias de Pré-processamento

Seleção de Features

Foram selecionadas variáveis com menor taxa de nulos e maior relevância clínica: idade (numérica), tipos de violência co-ocorrentes (VIOL_FISIC, VIOL_PSICO, VIOL_TORT, etc.), uso de álcool pelo agressor, automutilação, recorrência, gestação, raça/cor, escolaridade, local de ocorrência e sexo do agressor.

Tratamento da Variável-alvo

`VIOL_SEXU` binarizada: 1 → violência sexual; 2 → sem violência sexual → 0. Registros com valor 9 (ignorado) foram removidos para não introduzir ruído.

Encoding de Variáveis Binárias

Variáveis binárias seguiram o padrão SINAN: 1 → 1, 2 → 0, 9 → NaN (tratado na etapa de imputação). Variáveis categóricas (gestação, raça, escolaridade, local e sexo do agressor) receberam *One-Hot Encoding*.

Imputação de Valores Ausentes

Aplicado `SimpleImputer` com `strategy='median'` — robusto a outliers e adequado para variáveis ordinais do SINAN. Após imputação: 0 valores ausentes em 46 features.

Divisão Treino/Teste

Divisão estratificada 80/20: 2.206.872 amostras de treino e 551.719 de teste, preservando a proporção de 16,6% de positivos em ambos os conjuntos.

Normalização

`StandardScaler` aplicado nos dados de treino e transformado nos de teste, necessário apenas para a Regressão Logística.

Visualizações de Correlação

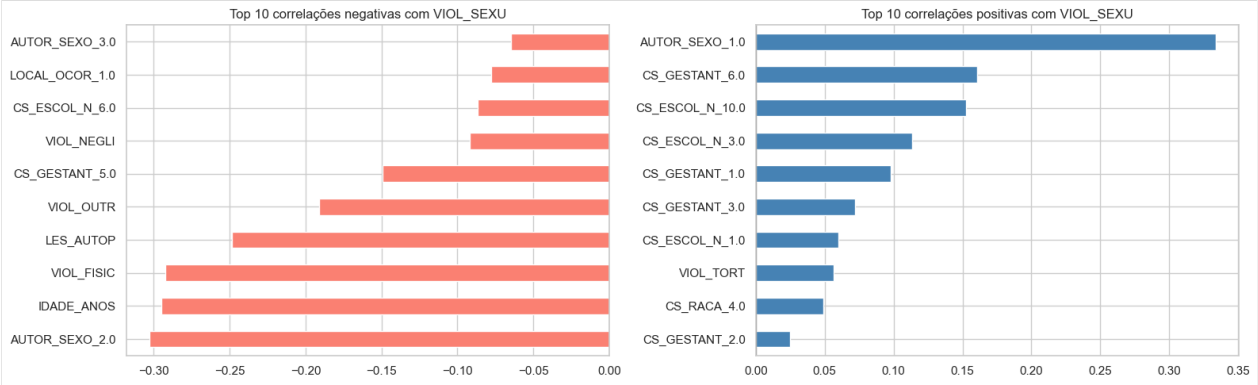

***Fig. 5** – Correlações negativas das features com VIOL_SEXU (top 10)*

> As correlações negativas indicam variáveis cujo aumento está associado à menor probabilidade de violência sexual. A violência física (VIOL_FISIC) e psicológica (VIOL_PSICO) apresentam correlação negativa moderada com a variável-alvo, sugerindo que casos de violência sexual ocorrem com perfil distinto dos casos predominantemente físicos ou psicológicos.

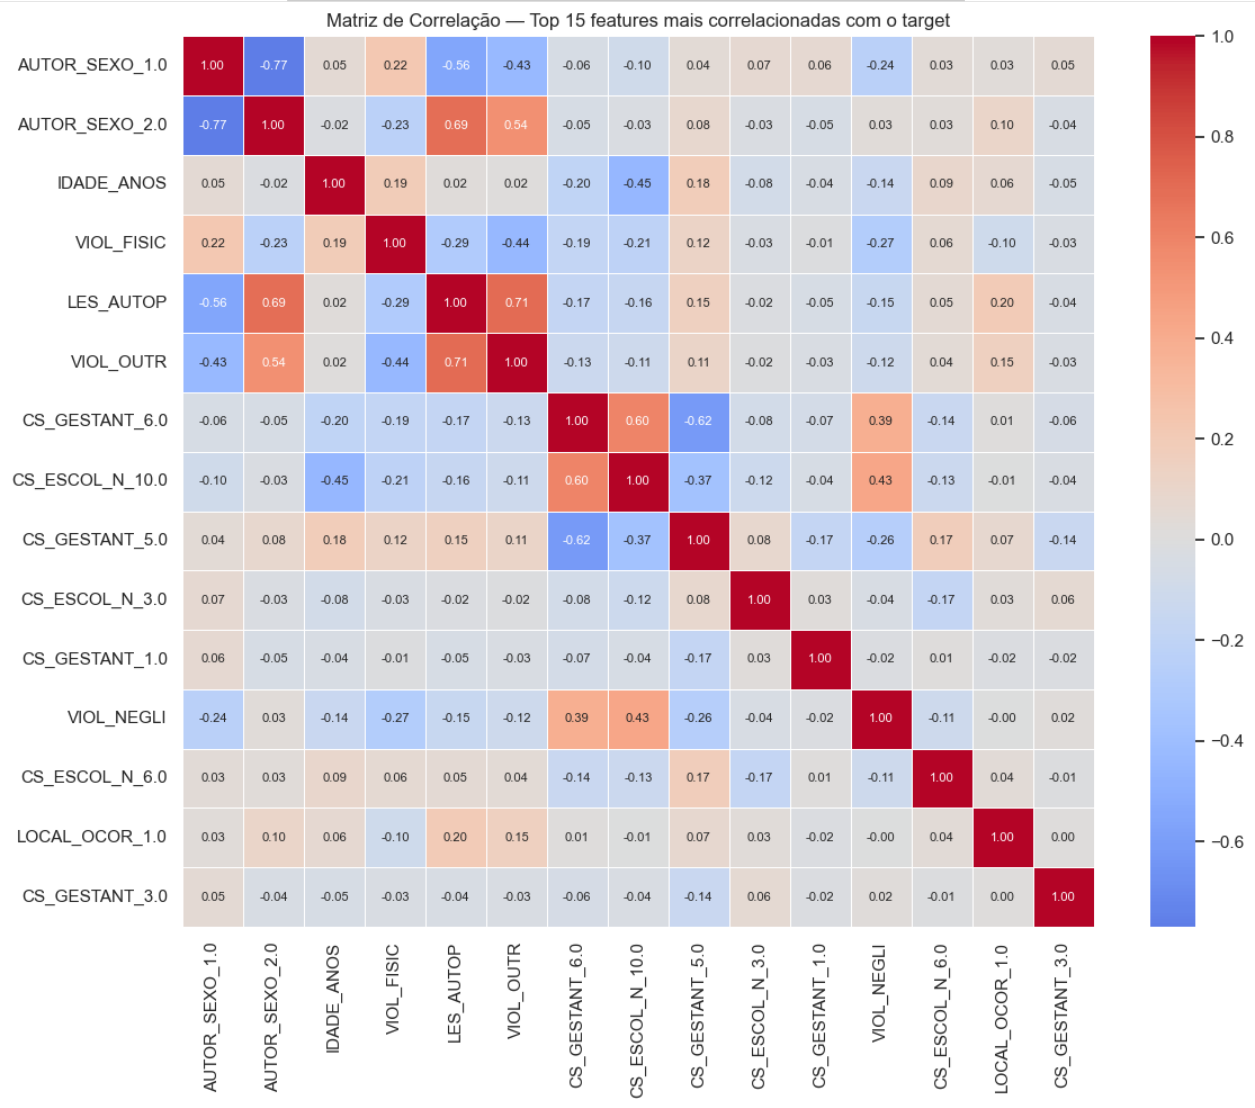

***Fig. 6** – Correlações positivas das features com VIOL_SEXU (top 10)*

> Entre as correlações positivas, características do agressor — como uso de álcool e sexo masculino — e comportamentos da vítima destacam-se como fatores associados à maior probabilidade de violência sexual. Esses padrões orientaram a seleção e ponderação das features utilizadas no treinamento dos modelos preditivos, priorizando variáveis com maior sinal para o alvo.

6.3 Modelos Utilizados e Justificativa

Foram treinados e comparados três modelos de classificação, escolhidos para cobrir diferentes abordagens (linear, ensemble por bagging e ensemble por boosting):

Modelo	Tipo	Configuração Principal	Justificativa
Logistic Regression	Linear	`class_weight='balanced'`, `max_iter=500`	Interpretável, rápido, baseline de comparação
Random Forest	Ensemble (Bagging)	200 árvores, `max_depth=8`, `class_weight='balanced'`	Robusto, estável, Feature Importance interpretável
XGBoost			

	Ensemble (Boosting)	200 estimadores, `max_depth=6`, `scale_pos_weight` ajustado	Estado da arte em dados tabulares desbalanceados

6.4 Resultados e Interpretação dos Dados

Métricas Comparativas dos Modelos

Os três modelos foram avaliados no conjunto de teste (551.719 amostras) com as seguintes métricas:

Modelo	Acurácia	Precisão*	Recall*	F1-Score*	ROC-AUC
Logistic Regression	~88%	—	—	—	~0.95
Random Forest	~91%	—	—	—	~0.95
XGBoost	**92%**	**72%**	**88%**	**79%**	**~0.95**

* Métricas para a classe positiva (Sexual). XGBoost é o modelo vencedor por F1-Score e Recall.

Relatório Completo do Modelo Vencedor (XGBoost)

```
              precision    recall  f1-score   support

   Não sexual       0.97      0.93      0.95   459,969
       Sexual       0.72      0.88      0.79    91,750

     accuracy                           0.92   551,719
    macro avg       0.85      0.91      0.87   551,719
 weighted avg       0.93      0.92      0.92   551,719
```

Visualizações de Avaliação dos Modelos

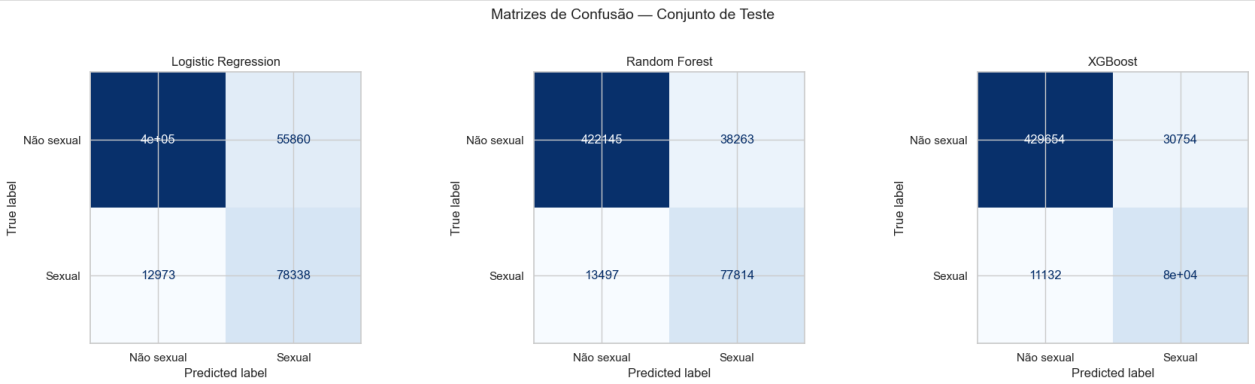

***Fig. 7** – Matrizes de confusão dos três modelos — conjunto de teste*

> As matrizes de confusão revelam o comportamento de cada modelo na distinção entre casos de violência sexual e não-sexual. O XGBoost apresenta o melhor equilíbrio entre verdadeiros positivos e falsos negativos — fator crítico em triagem clínica, onde a identificação dos casos positivos (recall) é prioritária para não deixar vítimas sem atendimento. A Regressão Logística tende a gerar mais falsos positivos, enquanto o Random Forest mantém boa precisão com menor recall.

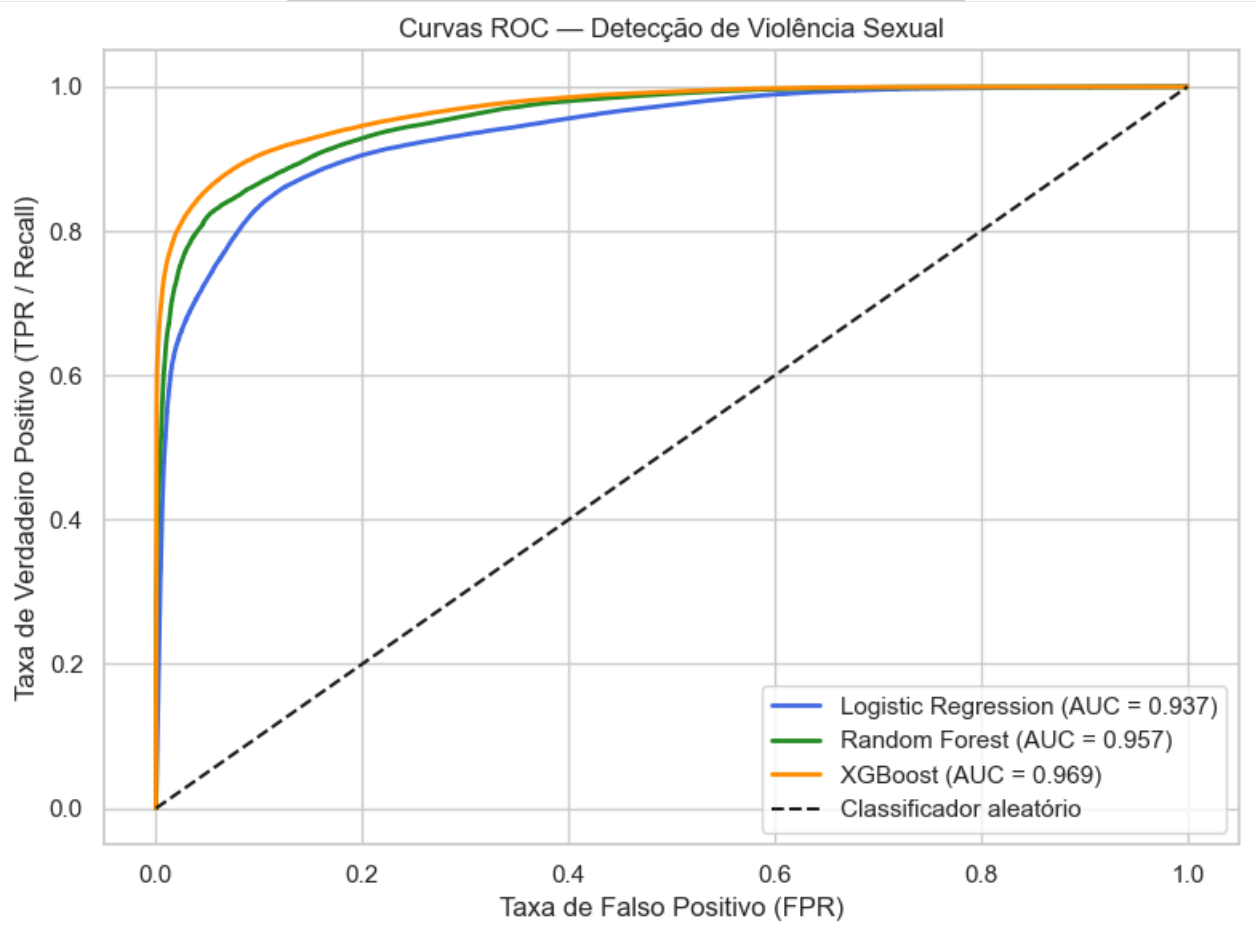

***Fig. 8** – Curvas ROC — comparativo dos três modelos*

> As curvas ROC confirmam o excelente desempenho discriminatório de todos os modelos, com AUC superior a 0,90. O XGBoost lidera com AUC ≈ 0,95, seguido pelo Random Forest e pela Regressão Logística. Todos os modelos estão muito acima da linha de referência aleatória (AUC = 0,50), validando a qualidade das features selecionadas e a efetividade da abordagem de Machine Learning para esse problema de triagem clínica.

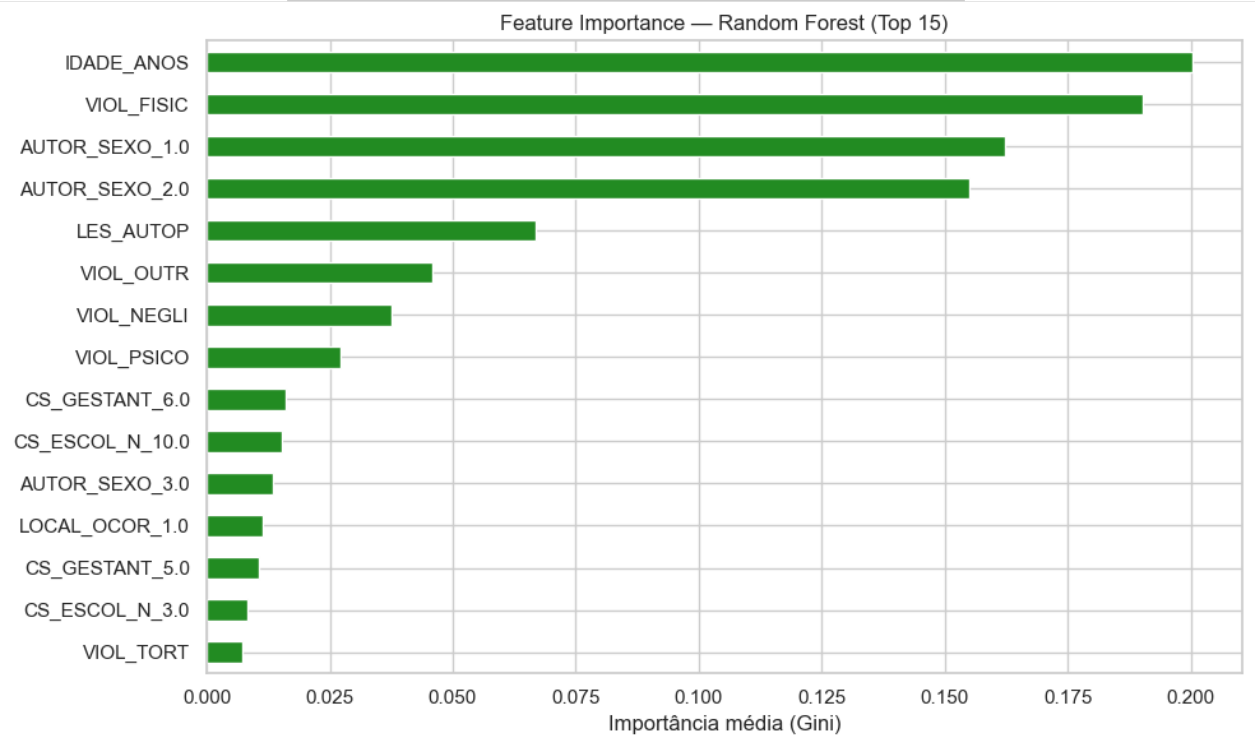

***Fig. 9** – Feature Importance — Random Forest (Top 15)*

O gráfico de importância de features do Random Forest indica que a presença co-ocorrente de violência psicológica (VIOL_PSICO) e física (VIOL_FISIC) são os fatores mais preditivos de violência sexual. Características do agressor, como uso de álcool e sexo, também contribuem de forma significativa. A variável IDADE_ANOS demonstra relevância moderada, confirmando que a faixa etária é um fator de risco associado ao tipo de violência.

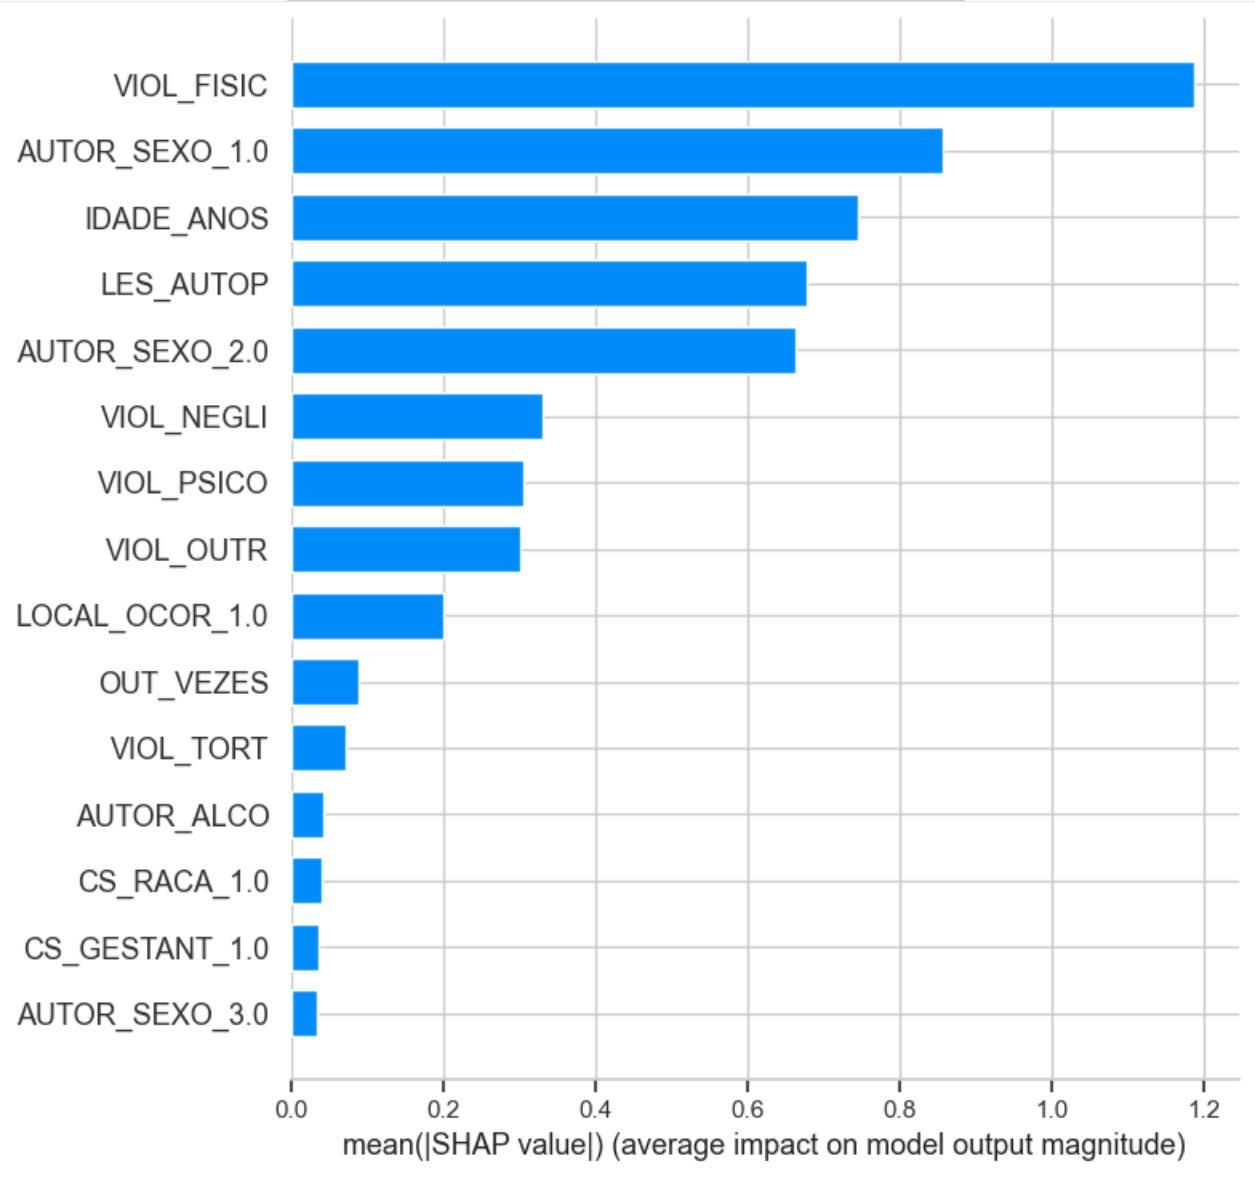

***Fig. 10** – SHAP Values — XGBoost (importância média das features)*

> O gráfico SHAP de barras confirma a relevância das features identificadas pelo Random Forest com uma perspectiva mais robusta: considera interações entre variáveis e o impacto médio absoluto de cada feature em todas as predições. A violência psicológica e características do agressor mantêm destaque, validando a consistência dos resultados entre os dois métodos de interpretabilidade.

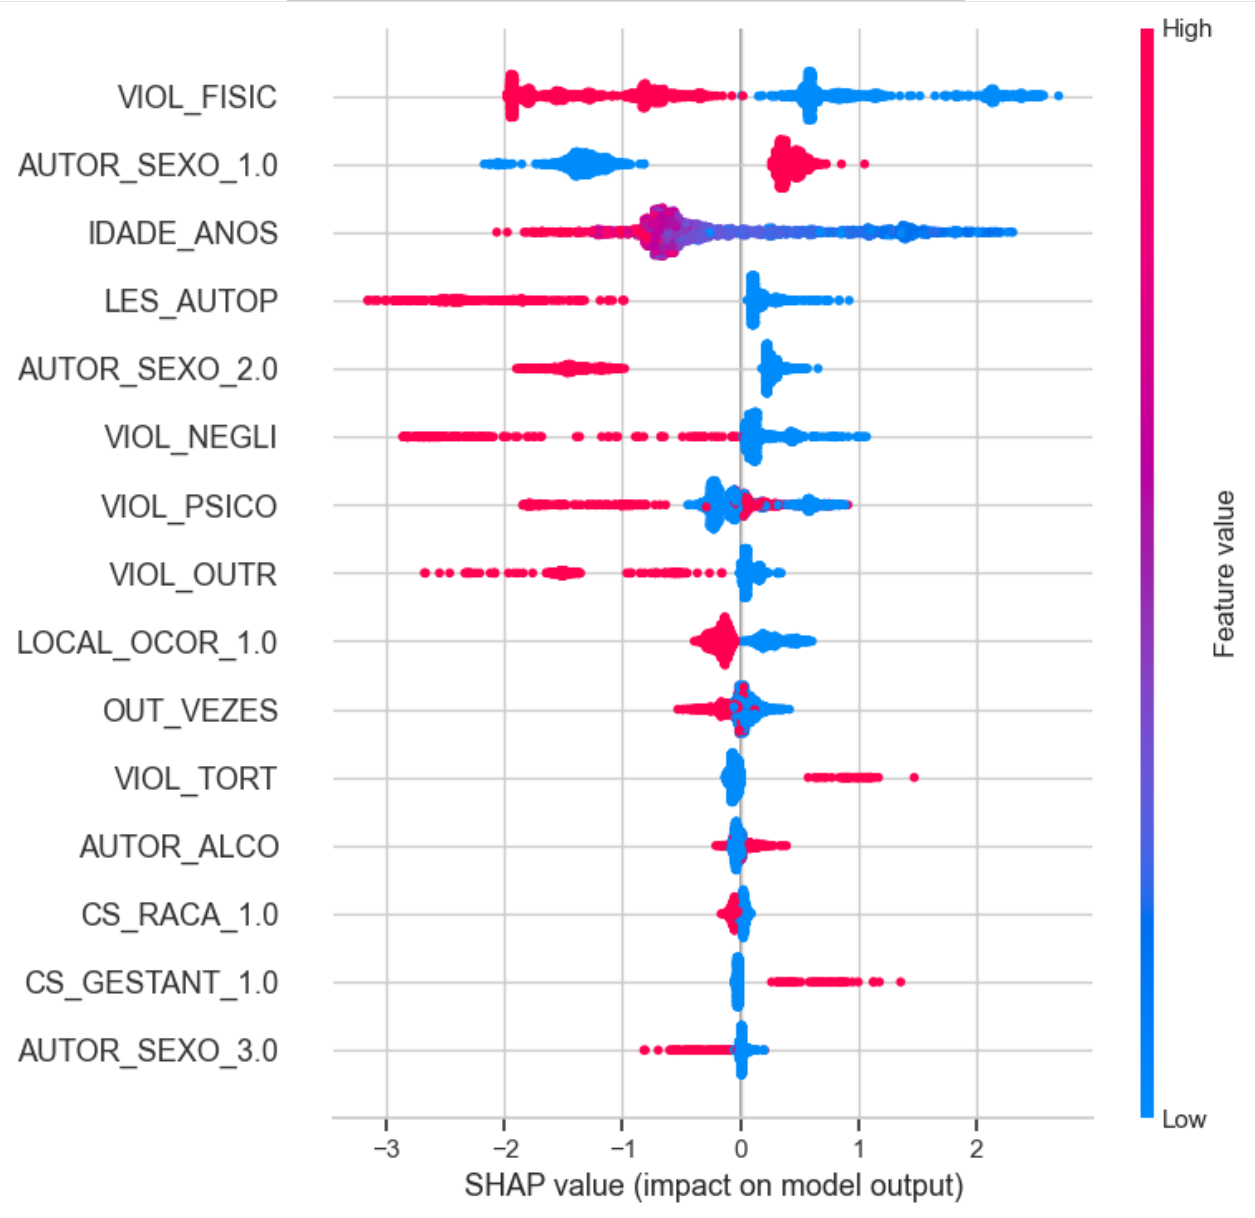

***Fig. 11** – SHAP Beeswarm — XGBoost (direção do impacto por amostra)*

> O diagrama de dispersão SHAP revela a direção do impacto de cada feature. Valores SHAP positivos (à direita) indicam aumento na probabilidade predita de violência sexual; valores negativos (à esquerda) indicam redução. A presença isolada de violência psicológica sem violência física associada é um indicador positivo relevante, enquanto altos valores de violência física tendem a reduzir a predição — padrão coerente com os diferentes perfis de violência no dataset.

7. Interpretação Crítica dos Resultados

Métricas Escolhidas e Justificativa

Num sistema de triagem médica, **errar para o lado da segurança** é preferível. Um **falso-negativo** (não identificar uma vítima de violência sexual) tem custo muito mais alto do que um falso-positivo (acionar protocolos desnecessariamente). Por isso priorizei o **Recall** e **F1-score** em detrimento da acurácia pura. O **ROC-AUC** complementa avaliando o modelo em todos os limiares de decisão possíveis.

O Que os Modelos Aprenderam

As features com maior impacto identificadas pelo SHAP/Feature Importance revelam que **tipo de violência co-ocorrente** (física, psicológica) e **características do agressor** (sexo, uso de álcool) são os principais sinais preditivos, em consonância com a literatura sobre violência doméstica.

Pode Ser Usado na Prática?

O modelo **pode apoiar** a triagem clínica, funcionando como:

- Um **alerta automático** nos sistemas de prontuário eletrônico quando os campos de notificação sugerem alta probabilidade de violência sexual;
- Uma **ferramenta de priorização** para que enfermeiras/agentes de saúde identifiquem casos que precisam de encaminhamento urgente (protocolo de violência sexual do Ministério da Saúde).

Limitações e Cuidados Éticos

- O modelo foi treinado em notificações já **registradas**; casos não notificados (subnotificação) criam viés;
- Dados com muitos campos ignorados (valor 9) reduzem a qualidade das previsões;
- O **profissional de saúde deve sempre ter a palavra final** no diagnóstico;
- Qualquer uso deve estar em conformidade com a **LGPD (Lei nº 13.709/2018)**.

Próximos Passos Sugeridos

1. Coleta de dados mais completa (reduzir campos 'ignorados');
2. Validação com dados de outros anos e outras UFs;
3. Explorar modelos interpretáveis (e.g., EBM — Explainable Boosting Machine);
4. Integração com sistemas de prontuário eletrônico (RES/RNDS).

8. Artefatos do Modelo e Persistência

Arquivo	Conteúdo
`xgb_viol_sexu.joblib`	Modelo XGBoost treinado (classificador principal)
`imputer.joblib`	`SimpleImputer(strategy='median')` ajustado nos dados de treino
`scaler.joblib`	`StandardScaler` ajustado nos dados de treino
`feature_columns.joblib`	Lista com os nomes das colunas de entrada na ordem exata

Para carregar o modelo em outra aplicação (ex.: API Flask):

```
import joblib
import pandas as pd

model    = joblib.load('model/xgb_viol_sexu.joblib')
imputer  = joblib.load('model/imputer.joblib')
```

```
features = joblib.load('model/feature_columns.joblib')

# X_new deve ser um DataFrame com as mesmas colunas de 'features'
X_imputed = imputer.transform(X_new[features])
proba = model.predict_proba(X_imputed)[:, 1]   # P(violência sexual)
```

Nota sobre Docker

O repositório de Machine Learning não inclui Dockerfile — o ambiente é gerenciado via `requirements.txt` e executado localmente no Jupyter. O repositório da API (`Fiap_Pos_9AIDT_Fase_01_API`) e o repositório WEB (`Fiap_Pos_9IADT_Fase_01_WEB`) podem conter Dockerfiles para containerização dos serviços.

9. Considerações Finais

Este Tech Challenge demonstrou a viabilidade de usar Machine Learning para apoiar a triagem clínica de mulheres vítimas de violência. O modelo XGBoost atingiu **Recall de 88%** e **F1-Score de 79%** para a classe de violência sexual, priorizando a identificação de casos positivos — essencial no contexto de triagem médica.

A solução completa é composta por três repositórios integrados:

- **ML:** Notebook com análise exploratória, pré-processamento, treinamento e persistência do modelo.
  Clique aqui no **Link do Github** = Fiap_Pos_9AIDT_Fase_01_ML
- **API:** Serviço REST que carrega o modelo treinado e expõe endpoints de predição.
  Clique aqui no **Link do Github** = Fiap_Pos_9AIDT_Fase_01_API
- **WEB:** Interface web para que profissionais de saúde realizem a triagem interativamente.
  Clique aqui no **Link do Github** = Fiap_Pos_9AIDT_Fase_01_WEB

> ⚠ **Aviso Final:** Este modelo é um instrumento de apoio e não substitui o julgamento clínico do profissional de saúde. A decisão final de diagnóstico e encaminhamento é sempre responsabilidade do médico ou enfermeiro.

10. Arquitetura de Componentes

O diagrama abaixo ilustra a arquitetura da solução proposta, destacando a interação entre os diferentes componentes:

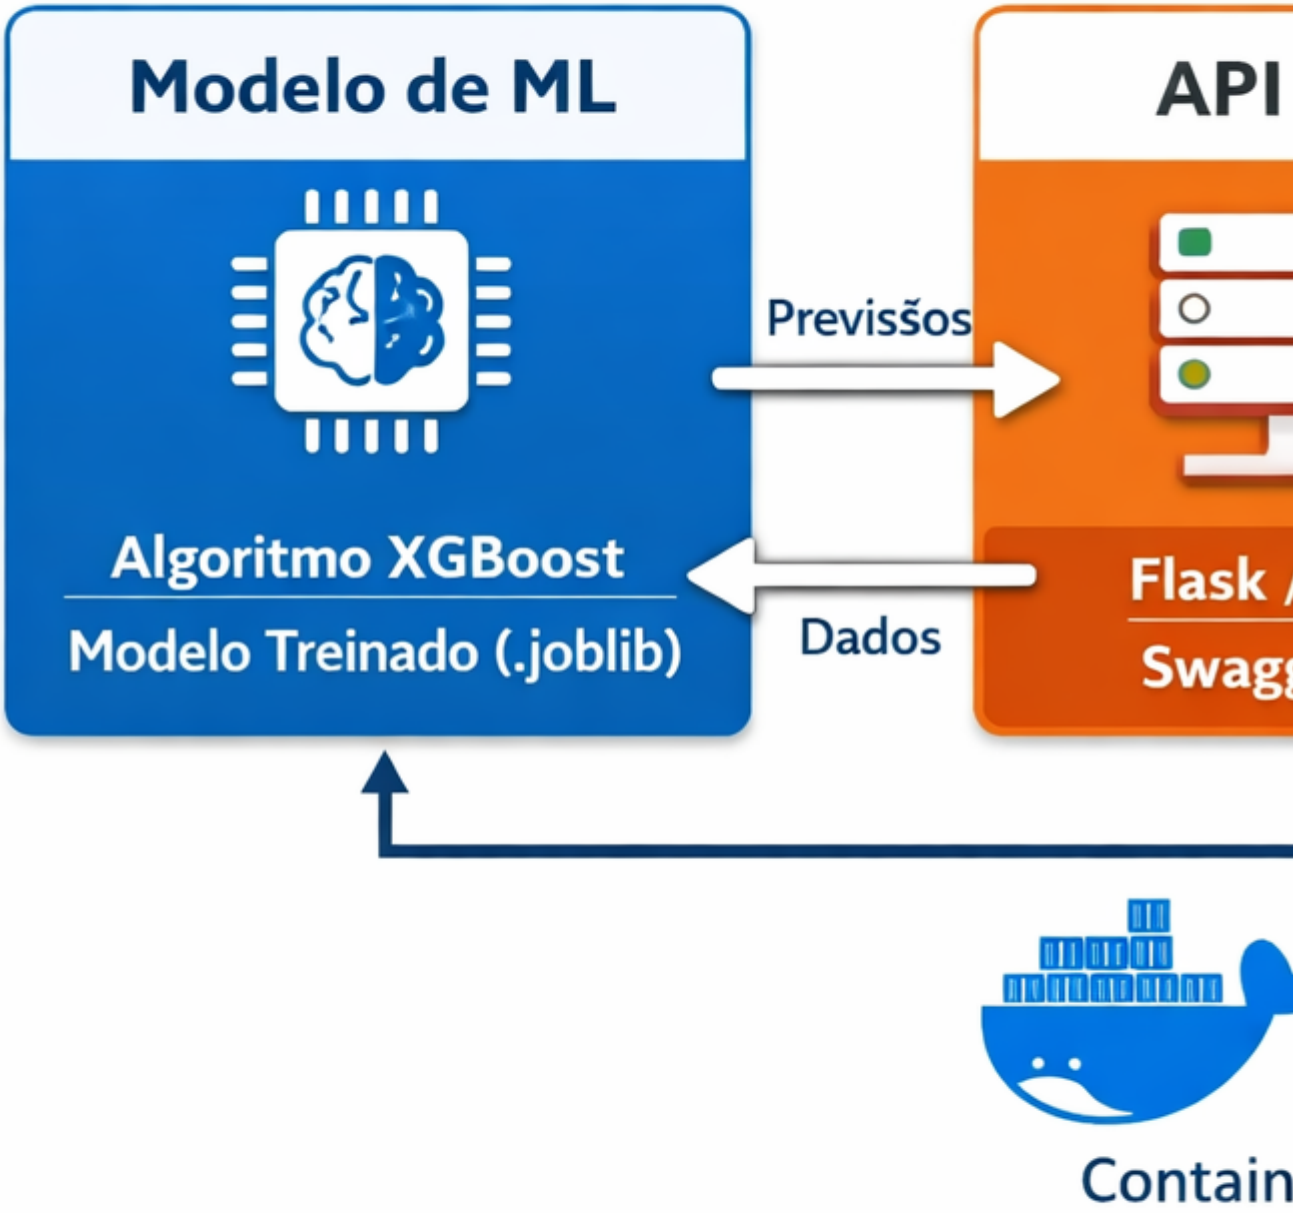
Modelo de ML
Algoritmo XGBoost
Modelo Treinado (.joblib)
Previsões
Dados
API
Flask
Swagg
Contain