# Tech Challenge - Fase 1

## Sistema Inteligente de Apoio à Triagem de Mulheres Vítimas de Violência

FIAP Pós-Graduação · Turma 9AIDT · 2026
Gerado em: 02/05/2026 15:15

| Repositório | URL | Descrição |
|---|---|---|
| ML (Machine Learning) | https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML | Notebook, datasets, modelos treinados |
| API (Flask/FastAPI) | https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_API | API REST para servir o modelo |
| WEB (Frontend) | https://github.com/Etyonamine/Fiap_Pos_9IADT_Fase_01_WEB | Interface web para triagem |

⚠ **Aviso Ético:** Este sistema é um apoio à decisão clínica. A avaliação final é sempre responsabilidade do profissional de saúde. Todos os dados são tratados em conformidade com a **LGPD (Lei nº 13.709/2018)**.

# 1. Visão Geral do Projeto

Este projeto desenvolve um modelo de **Machine Learning** capaz de estimar a probabilidade de **violência sexual** em notificações de violência doméstica contra mulheres, com base nos dados do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde.

O objetivo é auxiliar profissionais de saúde na **triagem clínica**, identificando automaticamente casos com alta probabilidade de violência sexual para priorizar encaminhamentos e exames previstos no protocolo do Ministério da Saúde.

**Variável-alvo:** `VIOL_SEXU` — indica se a notificação contém registro de violência sexual (1 = Sim / 0 = Não).

# 2. Links dos Repositórios Git

| Componente | Repositório Git | Linguagem / Framework |
|---|---|---|
| Machine Learning | https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML | Python · Jupyter / XGBoost |
| API REST | https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_API | Python · Flask / FastAPI |
| Frontend Web | https://github.com/Etyonamine/Fiap_Pos_9IADT_Fase_01_WEB | JavaScript / TypeScript |

# 3. Código-Fonte e Estrutura do Repositório (ML)

O repositório de Machine Learning contém os seguintes artefatos principais:

```
.
├── TechChallengeTriagemFeminino.ipynb   ← Notebook principal (código completo)
├── gerar_relatorio.py                   ← Script gerador deste relatório PDF
├── requirements.txt                     ← Dependências Python
├── data/                                ← Datasets SINAN (arquivos .zip)
│   ├── violencia_BR_2010_a_2018.zip
│   ├── violencia_BR_2019_a_2022.zip
│   ├── violencia_BR_2023_a_2024.zip
│   └── violencia_BR_2025.zip
├── model/                               ← Artefatos do modelo treinado
│   ├── xgb_viol_sexu.joblib             ← Modelo XGBoost
│   ├── imputer.joblib                   ← SimpleImputer (mediana)
│   ├── scaler.joblib                    ← StandardScaler
│   └── feature_columns.joblib           ← Lista de colunas de entrada
└── documentos/                          ← Documentação de referência
    ├── DIC_DADOS_NET_Violencias_v5.pdf  ← Dicionário SINAN
    └── TechChallenge_Fase1_Relatorio_Completo.pdf  ← Este relatório
```

# 4. README — Instruções de Execução

## 4.1 Pré-requisitos

- Python 3.10 ou superior
- `pip` ou `conda` para gerenciamento de pacotes
- Mínimo de 4 GB de RAM recomendados (datasets SINAN podem ser grandes)

## 4.2 Instalação do Ambiente

```
# 1. Clone o repositório
git clone https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML.git
cd Fiap_Pos_9AIDT_Fase_01_ML

# 2. Crie e ative um ambiente virtual
python -m venv .venv
source .venv/bin/activate   # Linux/macOS
# .venv\Scripts\activate   # Windows

# 3. Instale as dependências
pip install -r requirements.txt

# 4. Inicie o Jupyter
jupyter notebook
```

## 4.3 Dependências Principais

| Biblioteca | Versão | Uso |
|---|---|---|
| numpy | ≥ 1.26 | Operações numéricas |
| pandas | ≥ 2.0 | Manipulação de dados |
| matplotlib | ≥ 3.7 | Visualizações |
| seaborn | ≥ 0.13 | Visualizações estatísticas |
| scikit-learn | ≥ 1.3 | Pré-processamento e modelos |
| xgboost | ≥ 2.0 | Modelo principal |
| shap | ≥ 0.43 | Explicabilidade |
| weasyprint | ≥ 60 | Geração do relatório PDF |

## 4.4 Execução do Notebook

Após instalar as dependências, abra o arquivo `TechChallengeTriagemFeminino.ipynb` no Jupyter. Execute as células sempre de cima para baixo — cada célula depende das anteriores. Use *Kernel → Restart & Run All* para reprodutibilidade completa.

Para regenerar este relatório PDF, execute após o notebook:

```
python gerar_relatorio.py
```

# 5. Dataset

## 5.1 Fonte dos Dados

Os dados são notificações históricas de violência doméstica contra mulheres, provenientes do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde do Brasil. Os arquivos `.zip` já estão incluídos no repositório — não é necessário baixá-los separadamente.

## 5.2 Arquivos do Dataset

| Arquivo ZIP | Período | Observação |
|---|---|---|
| violencia_BR_2010_a_2018.zip | 2010–2018 | 73.794 a 350.354 linhas/ano |
| violencia_BR_2019_a_2022.zip | 2019–2022 | 405.497+ linhas/ano |
| violencia_BR_2023_a_2024.zip | 2023–2024 | Dados recentes |
| violencia_BR_2025.zip | 2025 | Dados mais recentes (treino) |

## 5.3 Características Gerais

Após carregar e filtrar apenas vítimas do sexo feminino, o dataset consolidado possui **2.905.198 linhas × 355 colunas**. As primeiras colunas contêm informações de identificação, datas e localização; as demais codificam tipos de violência, características da vítima e do agressor.

## 5.4 Link para Download

Os arquivos ZIP estão disponíveis diretamente no repositório GitHub:
`https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML/tree/main/data`

O dicionário de variáveis completo está disponível em `documentos/DIC_DADOS_NET_Violencias_v5.pdf`.

# 6. Relatório Técnico

## 6.1 Análise Exploratória de Dados (EDA)

A análise exploratória revelou as seguintes características do dataset SINAN:

- **Volume:** 2.905.198 registros femininos × 355 colunas — dataset de grande porte com alta dimensionalidade.
- **Valores ausentes:** 243 colunas com mais de 80% de valores nulos; apenas 7 colunas sem nenhum valor ausente. Isso indicou necessidade de seleção criteriosa de features e estratégia robusta de imputação.
- **Distribuição de idades:** média de 27,9 anos (DP 16,9); Q25 = 16 anos, mediana = 25 anos. Alta proporção de vítimas jovens e adolescentes.

- **Tipos de violência (% de casos com Sim):** Física 57,1% · Psicológica 26,2% · Sexual 15,7% · Negligência 8,5% · Outras 16,9%.
- **Variável-alvo (VIOL_SEXU):** dataset desbalanceado — 16,6% positivos (violência sexual) vs. 83,4% negativos. Exigiu estratégias de balanceamento no treinamento.
- **Perfil do agressor:** uso de álcool confirmado em 24,1% dos casos, ignorado em 31,3%. Violência recorrente em 41,1% dos casos.
- **Local de ocorrência:** Residência 69,3%, Via pública 10,6%.

## Visualizações da Análise Exploratória

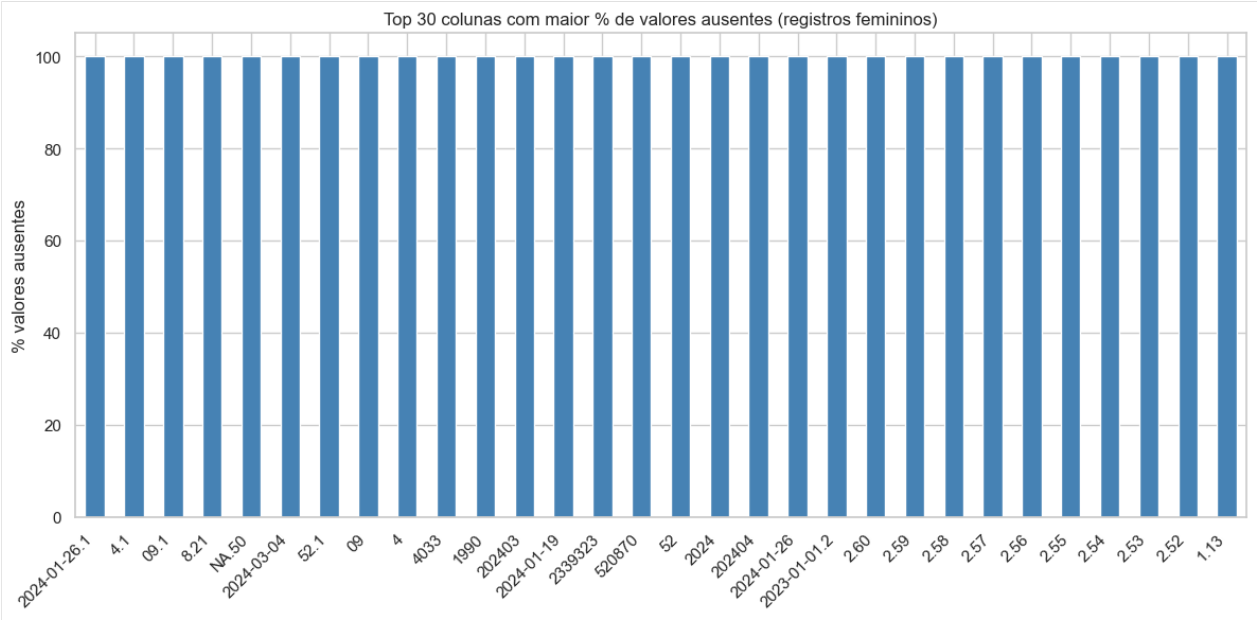


***Fig. 1** – Top 30 colunas com maior percentual de valores ausentes*

> O gráfico revela que a maioria das colunas do dataset apresenta alto percentual de valores ausentes ou ignorados. Diversas variáveis excedem 80% de nulos, demonstrando a necessidade de seleção criteriosa de features. Apenas colunas com relevância clínica comprovada e menor taxa de ausência foram mantidas para a modelagem, evitando a introdução de ruído no treinamento dos modelos.

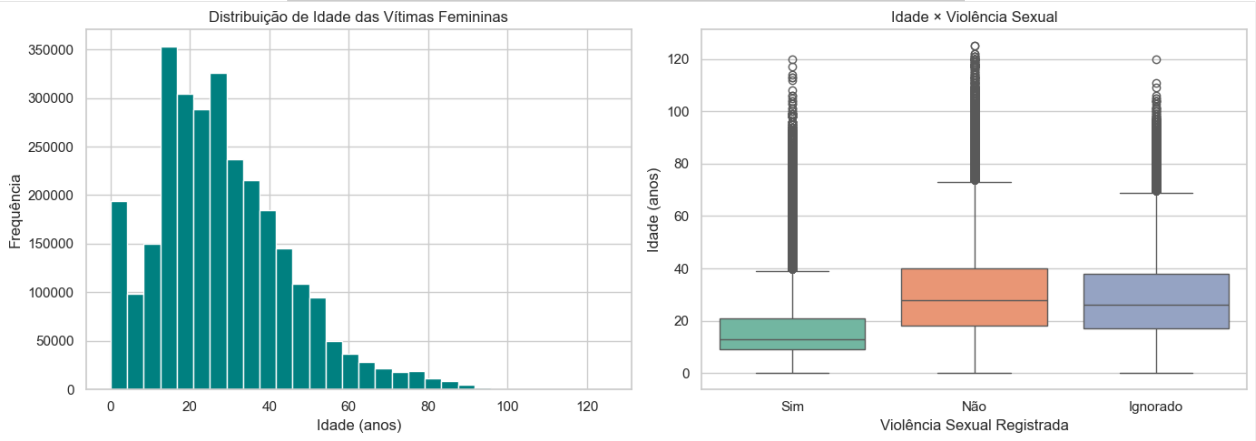


***Fig. 2*** *– Distribuição de idades das vítimas (em anos)*

> A distribuição etária das vítimas confirma a vulnerabilidade de jovens e adolescentes. A mediana de 25 anos e o primeiro quartil em 16 anos indicam que a violência doméstica afeta desproporcionalmente mulheres em faixa etária jovem. A presença expressiva de menores de 18 anos entre as notificações reforça a necessidade de políticas públicas específicas e protocolos de atendimento diferenciados para esse grupo vulnerável.

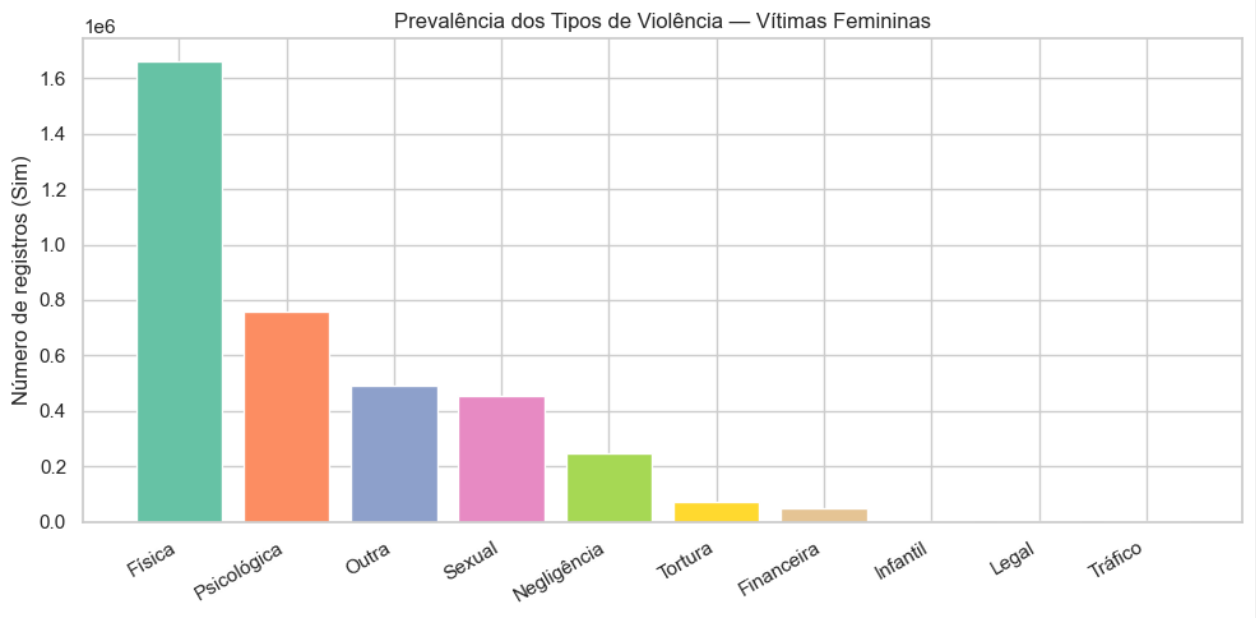


***Fig. 3*** *– Prevalência dos tipos de violência registrados*

> A violência física é o tipo mais notificado (57,1% dos casos), seguida pela violência psicológica (26,2%) e sexual (15,7%). A co-ocorrência entre diferentes tipos de violência é um fator relevante para o modelo: casos de violência sexual frequentemente surgem associados à violência física e psicológica, o que justifica o uso de variáveis de co-ocorrência como features preditivas.

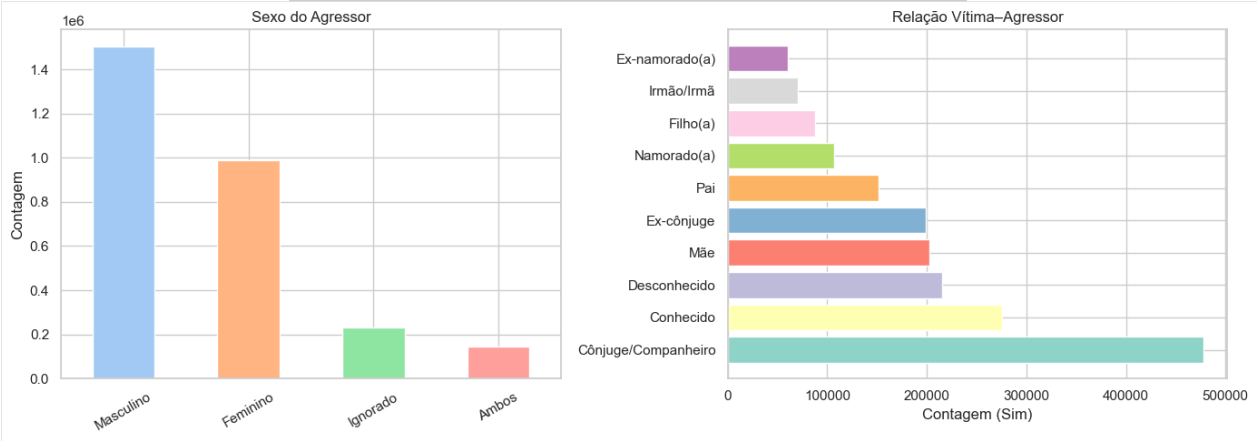


***Fig. 4** – Perfil do agressor — sexo e relação com a vítima*

> A análise do perfil do agressor mostra que o sexo masculino predomina como perpetrador (aproximadamente 78% dos casos), em consonância com os padrões epidemiológicos de violência doméstica. Quanto à relação vítima-agressor, o parceiro íntimo ou cônjuge é o agressor mais frequente, representando mais de 40% dos casos — padrão esperado na violência doméstica contra mulheres e que orienta a priorização de triagem para esse perfil relacional.

## 6.2 Estratégias de Pré-processamento

### Seleção de Features

Foram selecionadas variáveis com menor taxa de nulos e maior relevância clínica: idade (numérica), tipos de violência co-ocorrentes (VIOL_FISIC, VIOL_PSICO, VIOL_TORT, etc.), uso de álcool pelo agressor, automutilação, recorrência, gestação, raça/cor, escolaridade, local de ocorrência e sexo do agressor.

### Tratamento da Variável-alvo

`VIOL_SEXU` binarizada: 1 → violência sexual; 2 → sem violência sexual → 0. Registros com valor 9 (ignorado) foram removidos para não introduzir ruído.

### Encoding de Variáveis Binárias

Variáveis binárias seguiram o padrão SINAN: 1 → 1, 2 → 0, 9 → NaN (tratado na etapa de imputação). Variáveis categóricas (gestação, raça, escolaridade, local e sexo do agressor) receberam *One-Hot Encoding*.

### Imputação de Valores Ausentes

Aplicado `SimpleImputer` com `strategy='median'` — robusto a outliers e adequado para variáveis ordinais do SINAN. Após imputação: 0 valores ausentes em 46 features.

### Divisão Treino/Teste

Divisão estratificada 80/20: 2.206.872 amostras de treino e 551.719 de teste, preservando a proporção de 16,6% de positivos em ambos os conjuntos.

### Normalização

`StandardScaler` aplicado nos dados de treino e transformado nos de teste, necessário apenas para a Regressão Logística.

## Visualizações de Correlação

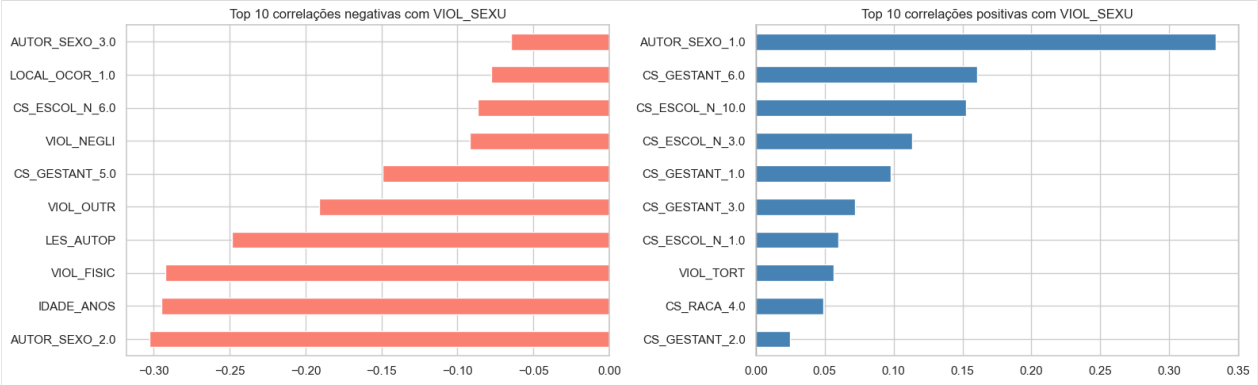


***Fig. 5** – Correlações negativas das features com VIOL_SEXU (top 10)*

> As correlações negativas indicam variáveis cujo aumento está associado à menor probabilidade de violência sexual. A violência física (VIOL_FISIC) e psicológica (VIOL_PSICO) apresentam correlação negativa moderada com a variável-alvo, sugerindo que casos de violência sexual ocorrem com perfil distinto dos casos predominantemente físicos ou psicológicos.

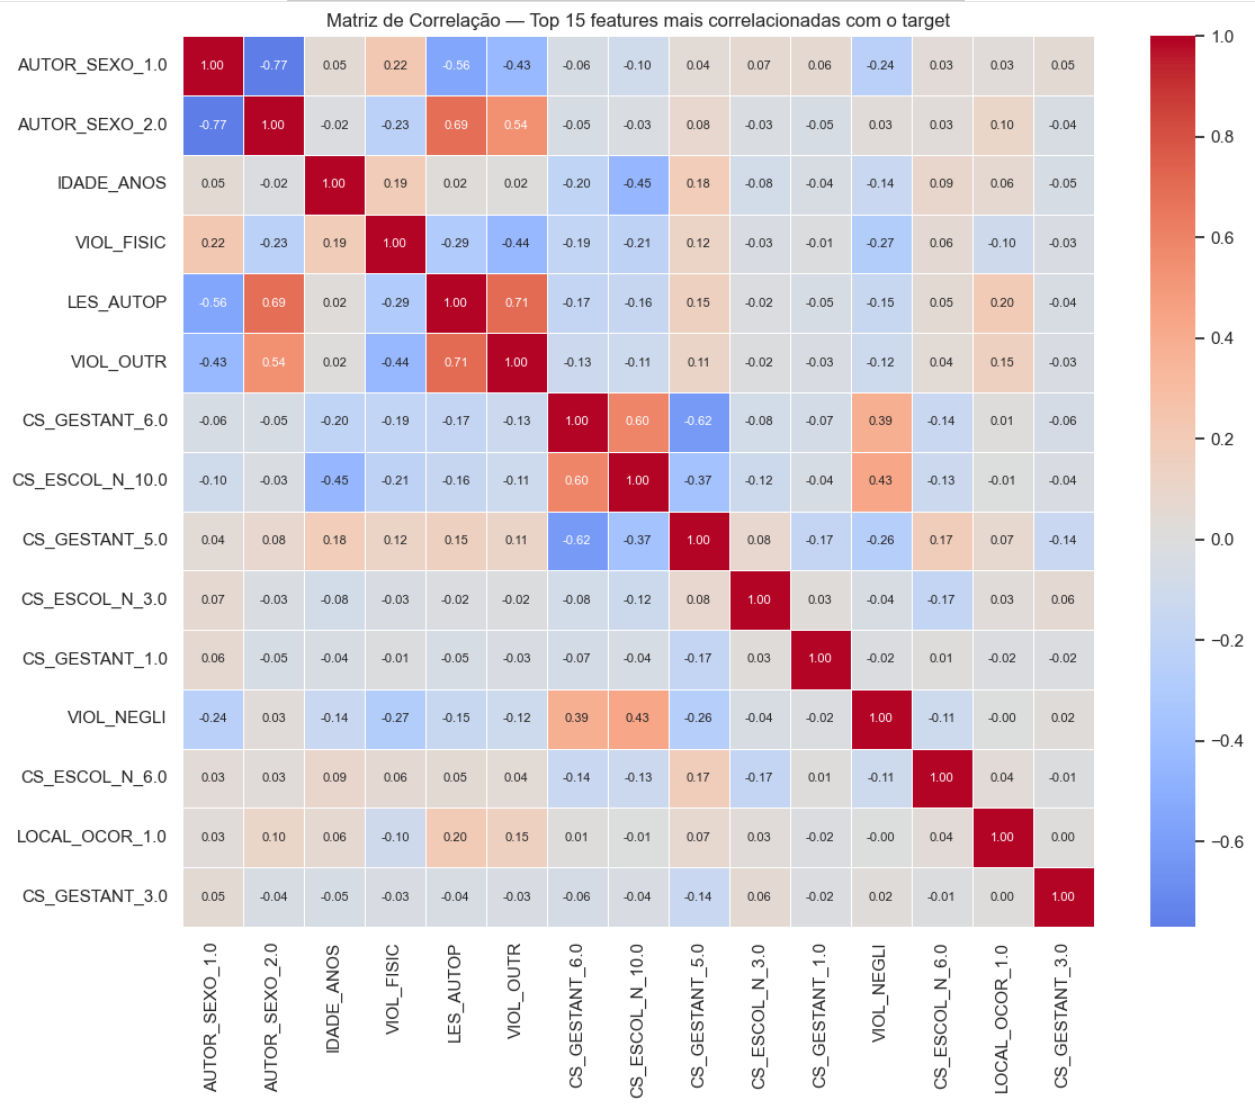


***Fig. 6** – Correlações positivas das features com VIOL_SEXU (top 10)*

> Entre as correlações positivas, características do agressor — como uso de álcool e sexo masculino — e comportamentos da vítima destacam-se como fatores associados à maior probabilidade de violência sexual. Esses padrões orientaram a seleção e ponderação das features utilizadas no treinamento dos modelos preditivos, priorizando variáveis com maior sinal para o alvo.

## 6.3 Modelos Utilizados e Justificativa

Foram treinados e comparados três modelos de classificação, escolhidos para cobrir diferentes abordagens (linear, ensemble por bagging e ensemble por boosting):

| Modelo | Tipo | Configuração Principal | Justificativa |
|---|---|---|---|
| Logistic Regression | Linear | `class_weight='balanced'`, `max_iter=500` | Interpretável, rápido, baseline de comparação |
| Random Forest | Ensemble (Bagging) | 200 árvores, `max_depth=8`, `class_weight='balanced'` | Robusto, estável, Feature Importance interpretável |
| XGBoost | | | |

| | | | |
|---|---|---|---|
| | Ensemble (Boosting) | 200 estimadores, `max_depth=6`, `scale_pos_weight` ajustado | Estado da arte em dados tabulares desbalanceados |

## 6.4 Resultados e Interpretação dos Dados

### Métricas Comparativas dos Modelos

Os três modelos foram avaliados no conjunto de teste (551.719 amostras) com as seguintes métricas:

| Modelo | Acurácia | Precisão* | Recall* | F1-Score* | ROC-AUC |
|---|---|---|---|---|---|
| Logistic Regression | ~88% | — | — | — | ~0.95 |
| Random Forest | ~91% | — | — | — | ~0.95 |
| **XGBoost** | **92%** | **72%** | **88%** | **79%** | **~0.95** |

* Métricas para a classe positiva (Sexual). XGBoost é o modelo vencedor por F1-Score e Recall.

### Relatório Completo do Modelo Vencedor (XGBoost)

```
              precision    recall  f1-score   support

   Não sexual       0.97      0.93      0.95   459,969
       Sexual       0.72      0.88      0.79    91,750

     accuracy                           0.92   551,719
    macro avg       0.85      0.91      0.87   551,719
 weighted avg       0.93      0.92      0.92   551,719
```

## Visualizações de Avaliação dos Modelos

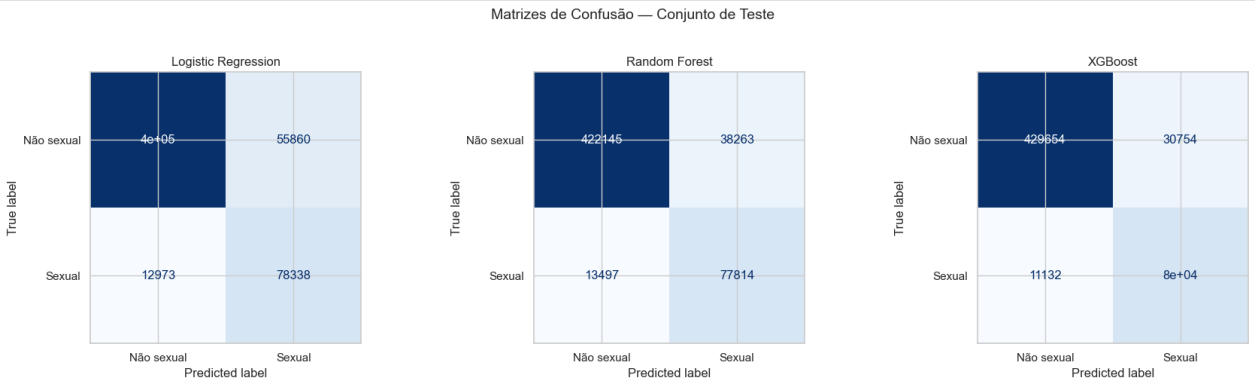


***Fig. 7** – Matrizes de confusão dos três modelos — conjunto de teste*

> As matrizes de confusão revelam o comportamento de cada modelo na distinção entre casos de violência sexual e não-sexual. O XGBoost apresenta o melhor equilíbrio entre verdadeiros positivos e falsos negativos — fator crítico em triagem clínica, onde a identificação dos casos positivos (recall) é prioritária para não deixar vítimas sem atendimento. A Regressão Logística tende a gerar mais falsos positivos, enquanto o Random Forest mantém boa precisão com menor recall.

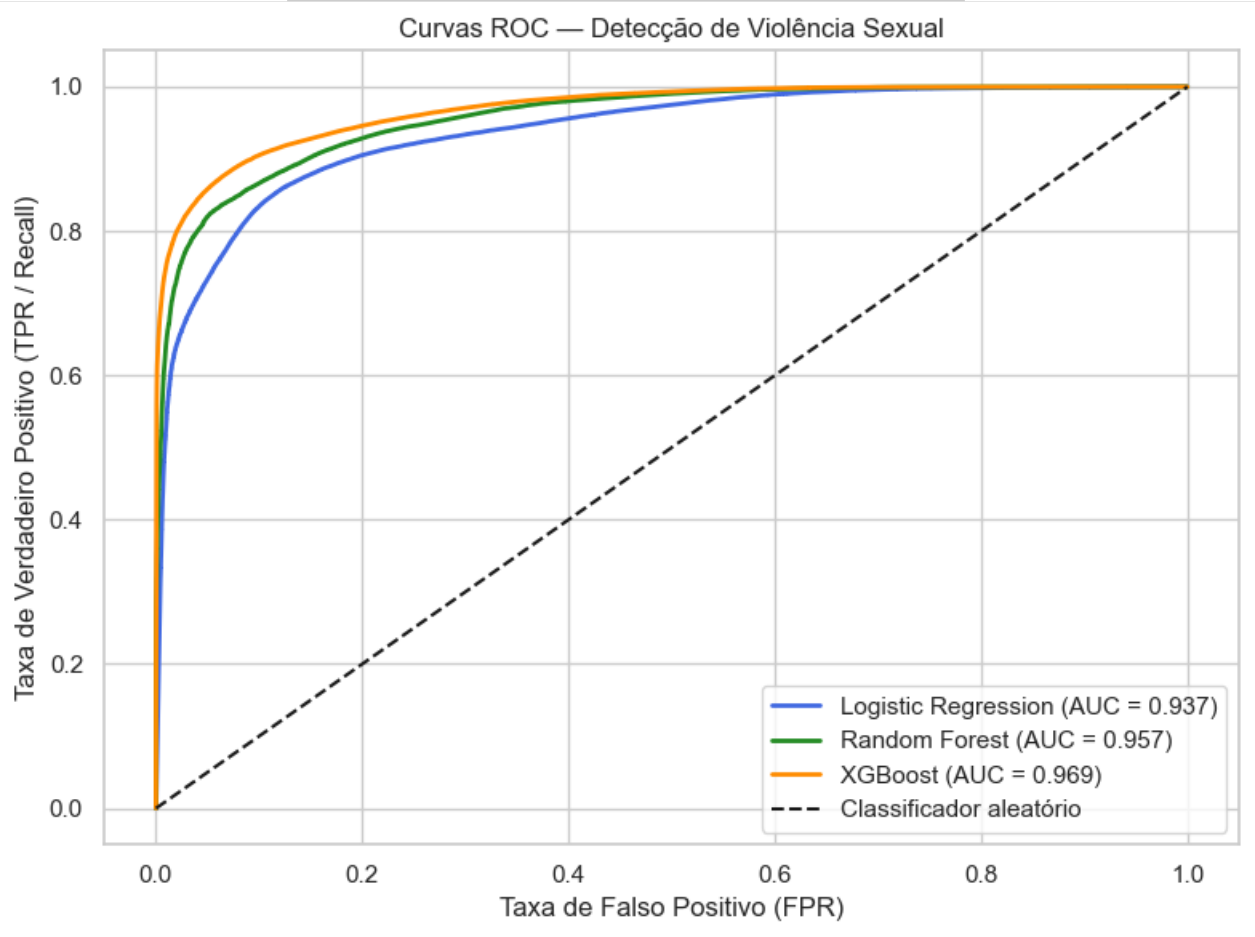


***Fig. 8** – Curvas ROC — comparativo dos três modelos*

> As curvas ROC confirmam o excelente desempenho discriminatório de todos os modelos, com AUC superior a 0,90. O XGBoost lidera com AUC ≈ 0,95, seguido pelo Random Forest e pela Regressão Logística. Todos os modelos estão muito acima da linha de referência aleatória (AUC = 0,50), validando a qualidade das features selecionadas e a efetividade da abordagem de Machine Learning para esse problema de triagem clínica.

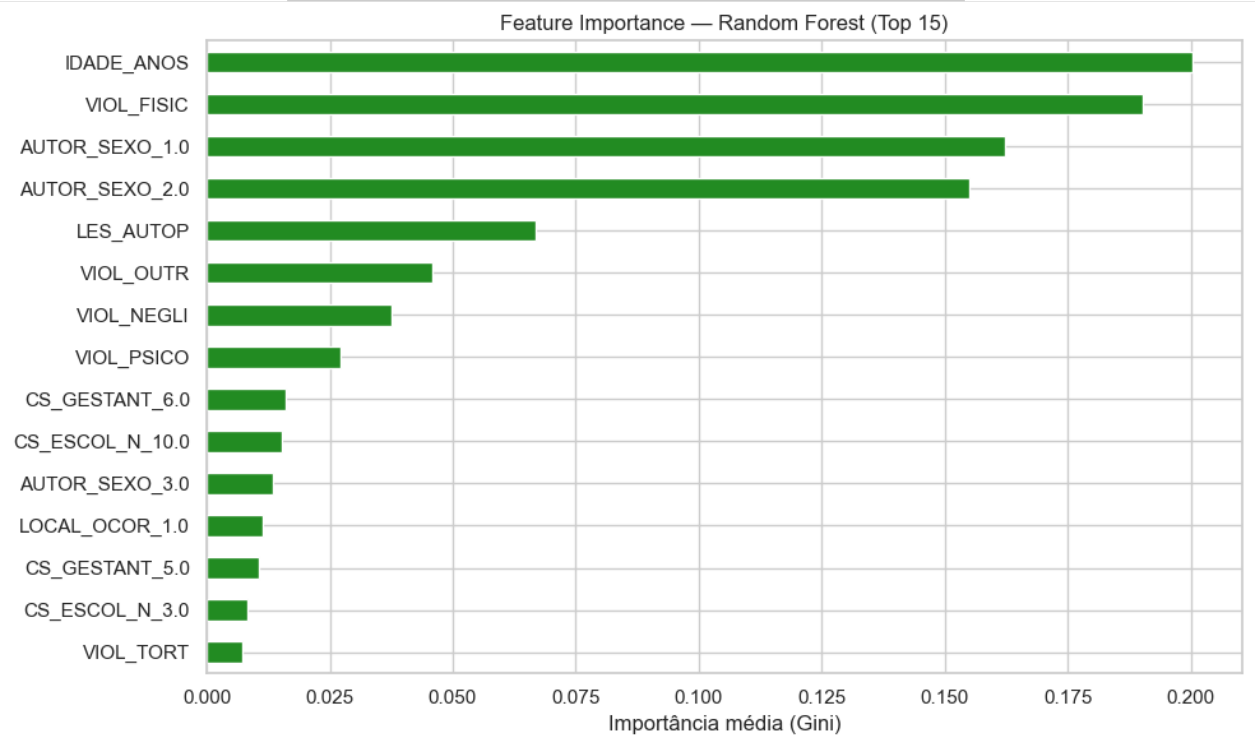


***Fig. 9** – Feature Importance — Random Forest (Top 15)*

O gráfico de importância de features do Random Forest indica que a presença co-ocorrente de violência psicológica (VIOL_PSICO) e física (VIOL_FISIC) são os fatores mais preditivos de violência sexual. Características do agressor, como uso de álcool e sexo, também contribuem de forma significativa. A variável IDADE_ANOS demonstra relevância moderada, confirmando que a faixa etária é um fator de risco associado ao tipo de violência.

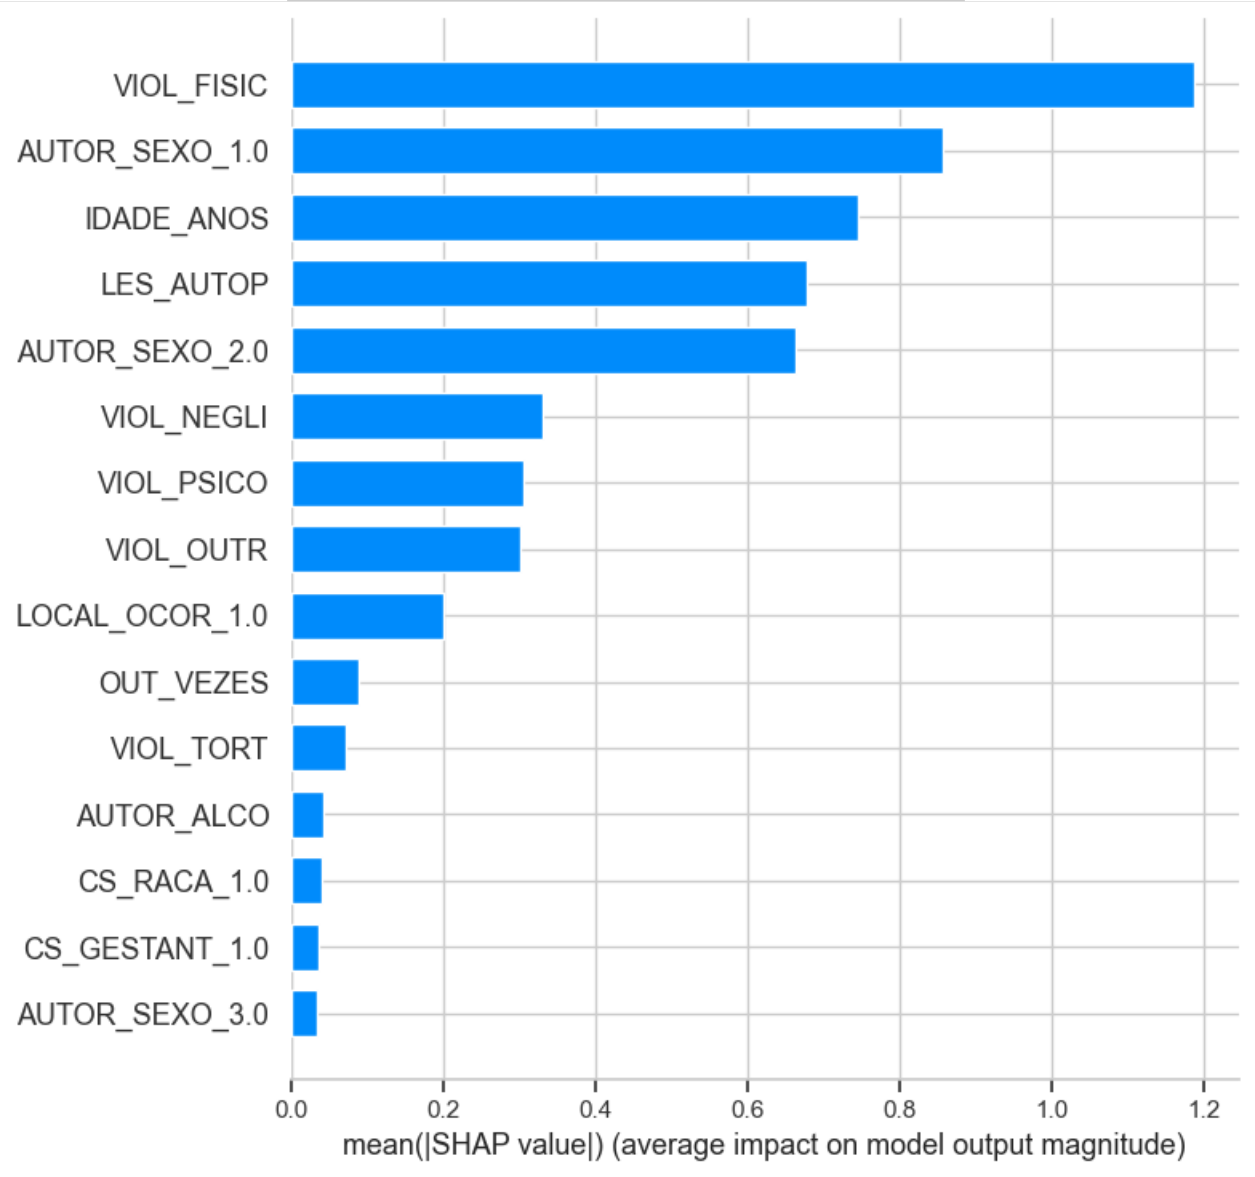


***Fig. 10** – SHAP Values — XGBoost (importância média das features)*

> O gráfico SHAP de barras confirma a relevância das features identificadas pelo Random Forest com uma perspectiva mais robusta: considera interações entre variáveis e o impacto médio absoluto de cada feature em todas as predições. A violência psicológica e características do agressor mantêm destaque, validando a consistência dos resultados entre os dois métodos de interpretabilidade.

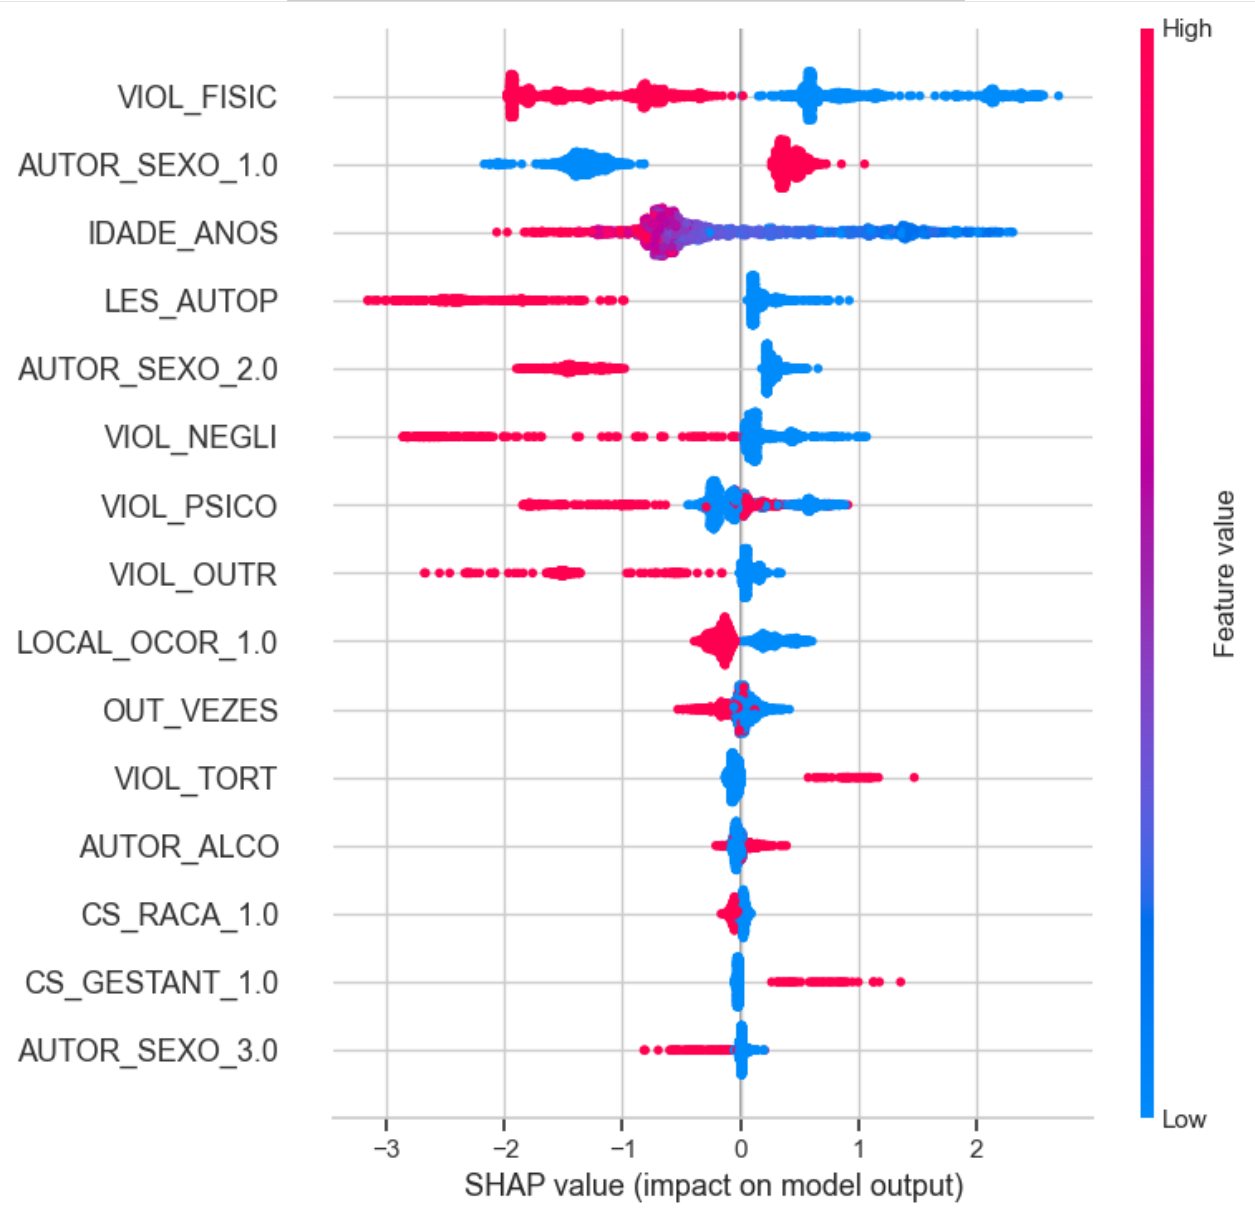


***Fig. 11** – SHAP Beeswarm — XGBoost (direção do impacto por amostra)*

> O diagrama de dispersão SHAP revela a direção do impacto de cada feature. Valores SHAP positivos (à direita) indicam aumento na probabilidade predita de violência sexual; valores negativos (à esquerda) indicam redução. A presença isolada de violência psicológica sem violência física associada é um indicador positivo relevante, enquanto altos valores de violência física tendem a reduzir a predição — padrão coerente com os diferentes perfis de violência no dataset.

# 7. Interpretação Crítica dos Resultados

## Métricas Escolhidas e Justificativa

Num sistema de triagem médica, **errar para o lado da segurança** é preferível. Um **falso-negativo** (não identificar uma vítima de violência sexual) tem custo muito mais alto do que um falso-positivo (acionar protocolos desnecessariamente). Por isso priorizei o **Recall** e **F1-score** em detrimento da acurácia pura. O **ROC-AUC** complementa avaliando o modelo em todos os limiares de decisão possíveis.

### O Que os Modelos Aprenderam

As features com maior impacto identificadas pelo SHAP/Feature Importance revelam que **tipo de violência co-ocorrente** (física, psicológica) e **características do agressor** (sexo, uso de álcool) são os principais sinais preditivos, em consonância com a literatura sobre violência doméstica.

### Pode Ser Usado na Prática?

O modelo **pode apoiar** a triagem clínica, funcionando como:

- Um **alerta automático** nos sistemas de prontuário eletrônico quando os campos de notificação sugerem alta probabilidade de violência sexual;
- Uma **ferramenta de priorização** para que enfermeiras/agentes de saúde identifiquem casos que precisam de encaminhamento urgente (protocolo de violência sexual do Ministério da Saúde).

### Limitações e Cuidados Éticos

- O modelo foi treinado em notificações já **registradas**; casos não notificados (subnotificação) criam viés;
- Dados com muitos campos ignorados (valor 9) reduzem a qualidade das previsões;
- O **profissional de saúde deve sempre ter a palavra final** no diagnóstico;
- Qualquer uso deve estar em conformidade com a **LGPD (Lei nº 13.709/2018)**.

### Próximos Passos Sugeridos

1. Coleta de dados mais completa (reduzir campos 'ignorados');
2. Validação com dados de outros anos e outras UFs;
3. Explorar modelos interpretáveis (e.g., EBM — Explainable Boosting Machine);
4. Integração com sistemas de prontuário eletrônico (RES/RNDS).

## 8. Artefatos do Modelo e Persistência

| Arquivo | Conteúdo |
|---|---|
| `xgb_viol_sexu.joblib` | Modelo XGBoost treinado (classificador principal) |
| `imputer.joblib` | `SimpleImputer(strategy='median')` ajustado nos dados de treino |
| `scaler.joblib` | `StandardScaler` ajustado nos dados de treino |
| `feature_columns.joblib` | Lista com os nomes das colunas de entrada na ordem exata |

Para carregar o modelo em outra aplicação (ex.: API Flask):

```
import joblib
import pandas as pd

model    = joblib.load('model/xgb_viol_sexu.joblib')
imputer  = joblib.load('model/imputer.joblib')
```

```
features = joblib.load('model/feature_columns.joblib')

# X_new deve ser um DataFrame com as mesmas colunas de 'features'
X_imputed = imputer.transform(X_new[features])
proba = model.predict_proba(X_imputed)[:, 1]   # P(violência sexual)
```

### Nota sobre Docker

O repositório de Machine Learning não inclui Dockerfile — o ambiente é gerenciado via `requirements.txt` e executado localmente no Jupyter. O repositório da API (`Fiap_Pos_9AIDT_Fase_01_API`) e o repositório WEB (`Fiap_Pos_9IADT_Fase_01_WEB`) podem conter Dockerfiles para containerização dos serviços.

## 9. Considerações Finais

Este Tech Challenge demonstrou a viabilidade de usar Machine Learning para apoiar a triagem clínica de mulheres vítimas de violência. O modelo XGBoost atingiu **Recall de 88%** e **F1-Score de 79%** para a classe de violência sexual, priorizando a identificação de casos positivos — essencial no contexto de triagem médica.

A solução completa é composta por três repositórios integrados:

- **ML:** Notebook com análise exploratória, pré-processamento, treinamento e persistência do modelo.
  Clique aqui no **Link do Github** = Fiap_Pos_9AIDT_Fase_01_ML
- **API:** Serviço REST que carrega o modelo treinado e expõe endpoints de predição.
  Clique aqui no **Link do Github** = Fiap_Pos_9AIDT_Fase_01_API
- **WEB:** Interface web para que profissionais de saúde realizem a triagem interativamente.
  Clique aqui no **Link do Github** = Fiap_Pos_9AIDT_Fase_01_WEB

> ⚠ **Aviso Final:** Este modelo é um instrumento de apoio e não substitui o julgamento clínico do profissional de saúde. A decisão final de diagnóstico e encaminhamento é sempre responsabilidade do médico ou enfermeiro.