🏥 Tech Challenge — FIAP Pós 9IADT 2026 — Fase 1

Sistema inteligente de apoio à triagem de mulheres vítimas de violência

> **Aviso Ético**: Este sistema é um **apoio à decisão clínica**. A avaliação final é sempre responsabilidade do profissional de saúde. Todos os dados são tratados em conformidade com a **LGPD (Lei nº 13.709/2018)**.

📋 Sumário

1. Visão Geral
2. Estrutura do Repositório
3. Pré-requisitos
4. Instalação do Ambiente
5. Preparação dos Dados
6. Como Usar o Jupyter Notebook
7. Fluxo do Notebook — Passo a Passo
8. Artefatos do Modelo
9. Modelos Treinados
10. Métricas e Avaliação
11. Considerações Éticas e Limitações

Visão Geral

Este projeto desenvolve um **modelo de Machine Learning** capaz de estimar a **probabilidade de violência sexual** em notificações de violência doméstica contra mulheres, com base nos dados do **SINAN** (Sistema de Informação de Agravos de Notificação) do Ministério da Saúde.

O objetivo é auxiliar profissionais de saúde na **triagem clínica**, identificando automaticamente casos com alta probabilidade de violência sexual para priorizar encaminhamentos e exames previstos no protocolo do Ministério da Saúde.

Variável-alvo: `VIOL_SEXU` — indica se a notificação contém registro de violência sexual (1 = Sim / 0 = Não).

Estrutura do Repositório

```
.
├── TechChallengeTriagemFeminino.ipynb  # Notebook principal
├── requirements.txt                    # Dependências Python
├── data/                               # Dados de entrada (arquivos .zip com
CSVs do SINAN)
```

```
│   ├── violencia_BR_2010_a_2018.zip
│   ├── violencia_BR_2019_a_2022.zip
│   ├── violencia_BR_2023_a_2024.zip
│   └── violencia_BR_2025.zip
├── model/                            # Artefatos do modelo treinado (gerados
pelo notebook)
│   ├── xgb_viol_sexu.joblib          # Modelo XGBoost treinado
│   ├── imputer.joblib                # Imputador de valores ausentes
(mediana)
│   ├── scaler.joblib                 # StandardScaler (Regressão Logística)
│   └── feature_columns.joblib        # Lista de colunas de entrada esperadas
└── documentos/                       # Documentação de referência
    ├── DIC_DADOS_NET_Violencias_v5.pdf # Dicionário de dados SINAN
    ├── IADT - Fase 1 - Tech challenge A.pdf
    └── relatorio-notebook-machine-learning.pdf
```

Pré-requisitos

- **Python** 3.14 ou superior
- **pip** ou **conda** para gerenciamento de pacotes
- Mínimo de **4 GB de RAM** recomendados (os datasets SINAN podem ser grandes)

Instalação do Ambiente

1. Clone o repositório

```
git clone https://github.com/Etyonamine/Fiap_Pos_9AIDT_Fase_01_ML.git
cd Fiap_Pos_9AIDT_Fase_01_ML
```

2. Crie e ative um ambiente virtual (recomendado)

```
python -m venv .venv
# Linux/macOS
source .venv/bin/activate
# Windows
.venv\Scripts\activate
```

3. Instale as dependências

```
pip install -r requirements.txt
```

As principais bibliotecas utilizadas são:

Biblioteca	Versão	Uso
`numpy`	≥ 1.26	Operações numéricas
`pandas`	≥ 2.0	Manipulação de dados
`matplotlib` / `seaborn`	≥ 3.7 / ≥ 0.13	Visualizações
`scikit-learn`	≥ 1.3	Pré-processamento e modelos
`xgboost`	≥ 2.0	Modelo principal (XGBoost)
`shap`	≥ 0.43	Explicabilidade do modelo
`jupyter`	≥ 1.0	Ambiente do notebook

Preparação dos Dados

Os dados são notificações históricas de violência doméstica contra mulheres, provenientes do **SINAN**, organizados em arquivos `.zip` dentro da pasta `data/`.

Os arquivos `.zip` já estão incluídos no repositório — não é necessário baixá-los separadamente. O notebook extrai e carrega os CSVs automaticamente na execução da primeira célula de código.

> O dicionário de variáveis completo está disponível em `documentos/DIC_DADOS_NET_Violencias_v5.pdf`.

Como Usar o Jupyter Notebook

1. Inicie o Jupyter

```
jupyter notebook
```

Ou, se preferir o JupyterLab:

```
jupyter lab
```

2. Abra o notebook principal

No navegador, navegue até o arquivo:

```
TechChallengeTriagemFeminino.ipynb
```

3. Execute as células em ordem

> ⚠ **IMPORTANTE**: Execute as células **sempre de cima para baixo**, na ordem em que aparecem. As células seguintes dependem de variáveis criadas nas anteriores.

Há duas formas de executar:

- **Célula por célula**: `Shift + Enter` para executar a célula atual e avançar para a próxima.
- **Todas de uma vez**: Menu `Kernel → Restart & Run All` para reiniciar o kernel e executar todo o notebook do início ao fim (recomendado para garantir reprodutibilidade).

4. Acompanhe os resultados

Cada seção gera saídas visuais (gráficos) e textuais (tabelas e métricas) diretamente abaixo das células. Não é necessário nenhuma configuração adicional.

Fluxo do Notebook — Passo a Passo

1 Importar o Dataset

As primeiras células de código definem e executam funções auxiliares que:

1. Localizam todos os arquivos `.zip` na pasta `data/`.
2. Extraem os CSVs contidos nos zips para a mesma pasta.
3. Carregam todos os CSVs com tentativas automáticas de encoding (`latin-1`, `utf-8`, `cp1252`).
4. Concatenam tudo em um único `DataFrame` (`dados_concatenados`).
5. Excluem os CSVs após o carregamento para economizar espaço em disco.

```
Saída esperada:
☑ Extraído: violencia_BR_2025.zip
📥 Carregado: violencia_BR_25.csv (linhas: XXXXX, colunas: XX)
🔗 DataFrames concatenados: X arquivos -> XXXXXX linhas
⏱  Tempo de carregamento: X.XXs
```

Em seguida, os dados são filtrados para manter apenas **vítimas do sexo feminino** (`CS_SEXO == 'F'`), gerando o DataFrame `dadosFemininos`.

---

2 Análise Exploratória de Dados (EDA)

Esta seção gera visualizações e estatísticas descritivas para entender o dataset:

- **Valores ausentes**: gráfico de barras com as 30 colunas com maior percentual de valores nulos.
- **Distribuição de idades**: histograma com a idade das vítimas (calculada a partir do campo codificado `NU_IDADE_N`).
- **Tipos de violência**: gráfico de prevalência de cada tipo de violência registrada (física, psicológica, sexual, etc.).
- **Perfil do agressor**: distribuição de sexo do agressor e relação vítima–agressor.
- **Repetição da violência**: percentual de casos em que a violência se repetiu.

3 Pré-processamento de Dados

Prepara os dados para a modelagem:

- **Seleção de features**: são utilizadas variáveis numéricas (idade), binárias (tipos de violência co-ocorrentes, uso de álcool pelo agressor, automutilação, recorrência) e categóricas (gestação, raça/cor, escolaridade, local de ocorrência, sexo do agressor).
- **Tratamento da variável-alvo** (`VIOL_SEXU`): binarizada em 1 (violência sexual) e 0 (demais), com remoção de registros com valor ignorado (9).
- **Encoding**: valores binários `1→1`, `2→0`, `9→NaN`; variáveis categóricas recebem One-Hot Encoding.
- **Imputação**: valores ausentes são substituídos pela **mediana** (`SimpleImputer`), robusta a outliers.
- **Análise de correlação**: heatmap e gráficos de barras mostrando as features com maior correlação positiva e negativa com o target.

---

4 Modelagem

Configura três modelos de classificação para comparação:

Modelo	Tipo	Configuration principal
Logistic Regression	Linear	`class_weight='balanced'`, `max_iter=500`
Random Forest	Ensemble (Bagging)	200 árvores, `max_depth=8`, `class_weight='balanced'`
XGBoost	Ensemble (Boosting)	200 estimadores, `max_depth=6`, `scale_pos_weight` ajustado para desbalanceamento

A divisão dos dados é **80% treino / 20% teste**, estratificada para preservar a proporção da classe positiva. Os dados de treino e teste são normalizados com `StandardScaler` para uso na Regressão Logística.

---

5 Treinamento e Avaliação dos Modelos

Treina os três modelos e produz:

- **Tabela comparativa de métricas**: Acurácia, Precisão, Recall, F1-Score e ROC-AUC para cada modelo (células em verde = melhor valor por métrica).
- **Matrizes de confusão**: visualização dos acertos e erros de cada modelo no conjunto de teste.
- **Curvas ROC**: comparação da capacidade discriminativa dos três modelos.
- **Feature Importance** (Random Forest): as 15 variáveis com maior importância média (Gini).
- **SHAP** (XGBoost): gráficos de barra e beeswarm mostrando o impacto de cada feature nas previsões do modelo.
- **Relatório de classificação** do melhor modelo (maior F1-Score).

> **Por que priorizar Recall e F1?** Num sistema de triagem clínica, um **falso-negativo** (não identificar uma vítima de violência sexual) tem custo muito mais alto do que um falso-positivo. Por isso, essas

> métricas têm prioridade sobre a acurácia pura.

---

6 Interpretação Crítica dos Resultados

Célula de texto com análise qualitativa dos resultados, incluindo:

- Justificativa das métricas escolhidas.
- O que os modelos aprenderam (principais features preditivas).
- Como o modelo pode ser usado na prática (alertas automáticos, priorização de casos).
- Limitações éticas (subnotificação, viés, conformidade com LGPD).
- Próximos passos sugeridos.

---

7 Persistência do Modelo

Salva os artefatos necessários para carregar o modelo treinado em uma API (ex.: Flask) sem precisar re-treinar:

```
joblib.dump(modelo_xgb,      "model/xgb_viol_sexu.joblib")
joblib.dump(imputer,         "model/imputer.joblib")
joblib.dump(scaler,          "model/scaler.joblib")
joblib.dump(feature_columns, "model/feature_columns.joblib")
```

Artefatos do Modelo

Após a execução completa do notebook, a pasta `model/` conterá:

Arquivo	Conteúdo
`xgb_viol_sexu.joblib`	Modelo XGBoost treinado (classificador principal)
`imputer.joblib`	`SimpleImputer(strategy='median')` ajustado nos dados de treino
`scaler.joblib`	`StandardScaler` ajustado nos dados de treino
`feature_columns.joblib`	Lista com os nomes das colunas de entrada, na ordem exata esperada pelo modelo

Para carregar o modelo em outra aplicação:

```
import joblib
import pandas as pd

model    = joblib.load("model/xgb_viol_sexu.joblib")
imputer  = joblib.load("model/imputer.joblib")
features = joblib.load("model/feature_columns.joblib")
```

```
# X_new deve ser um DataFrame com as mesmas colunas de 'features'
X_imputed = imputer.transform(X_new[features])
proba = model.predict_proba(X_imputed)[:, 1]  # probabilidade de violência
sexual
```

Modelos Treinados

#	Modelo	Tipo	Justificativa
1	**Random Forest**	Ensemble (Bagging)	Robusto, estável, boa interpretabilidade via Feature Importance
2	**XGBoost**	Ensemble (Boosting)	Alta performance em dados tabulares desbalanceados; modelo persistido
3	**Logistic Regression**	Linear	Interpretável, rápido, serve como baseline de comparação

---

Métricas e Avaliação

As métricas calculadas para cada modelo são:

Métrica	Descrição
Acurácia	Proporção de acertos no total
Precisão	Dos casos classificados como positivos, quantos realmente são
Recall	Dos casos positivos reais, quantos foram identificados *(métrica prioritária)*
F1-Score	Média harmônica entre Precisão e Recall *(métrica prioritária)*
ROC-AUC	Área sob a curva ROC; avalia o modelo em todos os limiares de decisão

---

Considerações Éticas e Limitações

- O modelo foi treinado em notificações **já registradas**; casos não notificados (subnotificação) introduzem viés.
- Campos preenchidos como "ignorado" (valor 9) reduzem a qualidade das previsões.
- O **profissional de saúde deve sempre ter a palavra final** no diagnóstico e encaminhamento.
- Qualquer uso deve estar em conformidade com a **LGPD (Lei nº 13.709/2018)**.

Documentos de Referência

- `documentos/DIC_DADOS_NET_Violencias_v5.pdf` — Dicionário de variáveis do SINAN
- `documentos/IADT - Fase 1 - Tech challenge A.pdf` — Enunciado do Tech Challenge
- `documentos/relatorio-notebook-machine-learning.pdf` — Relatório do projeto